

Trabajo de Fin de Grado:

Métodos estadísticos aplicados a la predicción de resultados en el fútbol



DOBLE GRADO EN MATEMÁTICAS Y ESTADÍSTICA

Autor: Pablo González Gómez

Tutora: Ana María Muñoz Reyes

2024-2025

Índice general

Resumen	II
Abstract	III
Índice de Tablas	IV
Índice de Figuras	VI
1. Introducción	1
2. Métodos de predicción de resultados deportivos	3
2.1. Modelo 1: Poisson con independencia	4
2.2. Modelo 2: Poisson con independencia y ponderación temporal	6
2.3. Modelo 3: Poisson bivariado	8
2.4. Modelo 4: Random Forest de regresión	12
2.5. Modelo 5: Random Forest de clasificación	16
2.6. Modelo 6: XGBoost de clasificación	18
3. Implementación en R	22
3.1. Datos y funciones	23
3.2. Poisson con independencia	24
3.3. Poisson con independencia y ponderación temporal	27
3.4. Poisson bivariado	31
3.5. Random Forest de regresión	34
3.6. Random Forest de clasificación	37
3.7. XGBoost de clasificación	45
4. Comparación de resultados y conclusiones	52
4.1. Comparación del rendimiento de los modelos	52
4.1.1. Modelos orientados a la predicción de goles	52
4.1.2. Modelos orientados a la predicción del resultado	53
4.2. Conclusiones	55
Bibliografía	56

Resumen

El objetivo de este trabajo es el estudio de distintas técnicas estadísticas aplicadas a la predicción de resultados deportivos, con especial interés en su utilidad en el ámbito de las apuestas. Para ello, se analizan varios modelos, tanto clásicos como de aprendizaje automático, orientados a predecir aspectos fundamentales del resultado de un evento deportivo, como el número de goles o el signo final (1X2).

Como aplicación concreta, se emplean datos reales de la primera división española de fútbol. Estos datos se utilizan para implementar y validar los modelos estudiados, aplicándolos al diseño de estrategias de apuestas en dos contextos distintos: por un lado, a partir de la predicción del resultado del partido en formato 1X2, y por otro, a través de la estimación del número total de goles en cada encuentro.

Abstract

The objective of this work is the study of various statistical techniques applied to the prediction of sports outcomes, with particular interest in their usefulness in the field of betting. To this end, several models, both classical and machine learning-based, are analyzed, focusing on the prediction of key aspects of a match outcome, such as the number of goals or the final result (1X2).

As a concrete application, real data from the Spanish first division football league are used. These data serve to implement and validate the models studied, applying them to the design of betting strategies in two different contexts: on the one hand, based on the prediction of the match result in 1X2 format, and on the other, through the estimation of the total number of goals in each match.

Índice de tablas

2.1. Resumen de variables predictoras utilizadas en el modelo	15
3.1. Habilidades estimadas Jornada 1 (Modelo 1)	24
3.2. Ganancia neta (Modelo 1)	26
3.3. Apuestas ganadas vs falladas (Modelo 1)	26
3.4. Ganancias por tipo de apuesta (Modelo 1)	27
3.5. Habilidades estimadas Jornada 1 (Modelo 2)	28
3.6. Ganancia neta (Modelo 2)	29
3.7. Apuestas ganadas vs falladas (Modelo 2)	30
3.8. Ganancias por tipo de apuesta (Modelo 2)	30
3.9. Habilidades estimadas Jornada 1 (Modelo 3)	31
3.10. Ganancia neta (Modelo 3)	33
3.11. Apuestas ganadas vs falladas (Modelo 3)	33
3.12. Ganancias por tipo de apuesta (Modelo 3)	33
3.13. Resultados validación cruzada (Modelo 4)	34
3.14. Primeras predicciones generadas (Modelo 4)	35
3.15. Ganancia neta (Modelo 4)	36
3.16. Apuestas ganadas vs falladas (Modelo 4)	36
3.17. Ganancias por tipo de apuesta (Modelo 4)	36
3.18. Frecuencia de clases (conjunto train)	38
3.19. Frecuencia de clases tras balanceo	38
3.20. Mejores modelos validación cruzada (Modelo 5)	38
3.21. Precisión media conjunto test (Modelo 5)	39
3.22. Precisión media 2023/2024 (Modelo 5)	40
3.23. IC al 95 % para las ganancias - Estrategia conservadora (Modelo 5)	41
3.24. IC al 95 % para las ganancias - Estrategia arriesgada (Modelo 5)	42
3.25. Ganancias por tipo de apuesta (Modelo 5)	42
3.26. Ganancias por rango de cuotas (Modelo 5)	43
3.27. Mejores modelos validación cruzada (Modelo 6)	46
3.28. Precisión media conjunto test (Modelo 6)	46
3.29. Precisión media 2023/2024 (Modelo 6)	47
3.30. IC al 95 % para las ganancias - Estrategia conservadora (Modelo 6)	48
3.31. IC al 95 % para las ganancias - Estrategia arriesgada (Modelo 6)	49
3.32. Ganancias por tipo de apuesta (Modelo 6)	49
3.33. Ganancias por rango de cuotas (Modelo 6)	50
4.1. Comparación de modelos de regresión (mercado Over/Under 2.5 goles) . .	52

4.2.	ROI por tipo de apuesta y modelo (Regresión)	53
4.3.	Comparación de precisión por clases (temporada 2023/2024)	53
4.4.	ROI por clase y modelo (Clasificación)	54
4.5.	ROI por rango de cuota y modelo (Clasificación)	54

Índice de figuras

3.1. Evolución de la habilidad ofensiva (Modelo 1)	25
3.2. Evolución de la habilidad defensiva (Modelo 1)	25
3.3. Ventaja de jugar en casa (Modelo 1)	26
3.4. Ganancias por tipo de apuesta (Modelo 1)	27
3.5. Evolución de la habilidad ofensiva (Modelo 2)	28
3.6. Evolución de la habilidad defensiva (Modelo 2)	29
3.7. Ganancias por tipo de apuesta (Modelo 2)	30
3.8. Evolución de la habilidad ofensiva (Modelo 3)	32
3.9. Evolución de la habilidad defensiva (Modelo 3)	32
3.10. Ganancias por tipo de apuesta (Modelo 3)	33
3.11. Importancia de las covariables (Modelo 4)	35
3.12. Ganancias por tipo de apuesta (Modelo 4)	37
3.13. Gráficos de normalidad para las ganancias (Modelo 5)	41
3.14. Ganancias por tipo de apuesta (Modelo 5)	42
3.15. Ganancias por rango de cuotas (Modelo 5)	43
3.16. Ganancias por equipo local (Modelo 5)	44
3.17. Ganancias por equipo visitante (Modelo 5)	44
3.18. Gráficos de normalidad para las ganancias (XGB)	48
3.19. Ganancias por tipo de apuesta (Modelo 6)	49
3.20. Ganancias por rango de cuotas (Modelo 6)	50
3.21. Ganancias por equipo local (Modelo 6)	51
3.22. Ganancias por equipo visitante (Modelo 6)	51

Capítulo 1

Introducción

En los últimos años, el uso de modelos estadísticos y técnicas de aprendizaje automático ha adquirido una gran relevancia en el ámbito de la predicción de resultados deportivos. Esta tendencia responde, en parte, al enorme impacto económico y social que tienen ciertos deportes a nivel mundial, lo que ha impulsado el interés por identificar patrones o relaciones que permitan anticipar los desenlaces de los encuentros con mayor precisión.

El presente Trabajo de Fin de Grado tiene como objetivo principal el análisis y la aplicación de diversas técnicas estadísticas para realizar predicciones sobre resultados deportivos. Como caso particular, el estudio se aplica a la Primera División española de fútbol.

Para ello, se implementan distintos enfoques de modelización basados en la distribución de Poisson, muy utilizada en contextos deportivos para predicción del número de goles, así como métodos de aprendizaje automático como los bosques aleatorios y el algoritmo XGBoost. Se plantean dos tipos principales de predicciones: por un lado, el número de goles anotados por ambos equipos en un partido determinado; y por otro, el resultado final del encuentro (victoria local, empate o victoria visitante).

Además del análisis predictivo, el trabajo incorpora una dimensión práctica mediante el diseño de estrategias de apuestas deportivas aplicadas a la Primera División del fútbol español. Concretamente, se evalúa si las predicciones obtenidas a partir de los modelos estadísticos pueden aprovecharse, en combinación con las cuotas ofrecidas por la casa de apuestas BET365, para desarrollar estrategias rentables económicamente. Se consideran dos enfoques distintos: uno basado en la predicción del resultado final del encuentro (1X2), y otro centrado en el mercado 'over/under', esto es, en anticipar si el número total de goles de un partido será superior o inferior a 2,5.

La estructura del trabajo se detalla a continuación. En el Capítulo 2 se describen en detalle las diferentes técnicas de modelado utilizadas para la predicción de resultados deportivos. Para cada una de ellas se presentan sus fundamentos teóricos, la metodología general de aplicación y su adaptación al caso concreto del fútbol profesional. El Capítulo 3 está dedicado a la implementación práctica de estas técnicas mediante el software R, así como al análisis de los resultados obtenidos en las distintas estrategias de predicción y apuestas. Por último, en el Capítulo 4 se realiza una comparativa del rendimiento de los modelos desarrollados, destacando sus principales fortalezas y limitaciones, y se presentan las conclusiones generales del trabajo, junto con algunas posibles líneas de mejora y extensión futura.

Capítulo 2

Métodos de predicción de resultados deportivos

En este capítulo se presentan los distintos modelos estadísticos empleados para abordar el problema de la predicción de resultados deportivos, combinando tanto enfoques clásicos como técnicas modernas de aprendizaje automático. Para cada modelo se describen sus fundamentos teóricos, su planteamiento metodológico en contextos deportivos generales y su adaptación específica al caso del fútbol profesional. Además, se detalla su implementación práctica sobre los datos utilizados en este trabajo.

Muchos de los enfoques presentados han sido desarrollados a partir de trabajos recopilados en el libro *Computer Science in Sport: Modeling, Simulation, Data Analysis and Visualization of Sports-Related Data* (Memmert, 2024), una obra de referencia en el campo del análisis estadístico aplicado al deporte.

Los modelos considerados abarcan desde formulaciones probabilísticas tradicionales, como la distribución de Poisson, hasta algoritmos más complejos basados en árboles de decisión, como Random Forest y XGBoost. Se distinguen dos enfoques predictivos en función del objetivo final. Por un lado, se desarrollan modelos de regresión destinados a predecir el número de goles anotados por cada equipo en un partido. Estas predicciones se emplean para construir una estrategia de apuestas centrada en el mercado 'over/under', es decir, en si el número total de goles en un partido será superior o inferior a 2,5. Por otro lado, se abordan modelos de clasificación orientados a predecir directamente el resultado del encuentro en términos de 1X2 (victoria local, empate o victoria visitante), los cuales servirán de base para diseñar un segundo plan de apuestas deportivas, esta vez vinculada al desenlace del partido.

En el capítulo siguiente (3) se analizará, a partir de los pronósticos generados, la viabilidad de obtener un retorno económico positivo mediante las estrategias propuestas.

2.1. Modelo 1: Poisson con independencia

La distribución de Poisson es un modelo clásico utilizado para describir el número de veces que ocurre un evento en un intervalo específico, generalmente de tiempo. Es especialmente adecuada para modelar recuentos discretos de eventos raros, como los goles en un partido de fútbol, fútbol sala, hockey o waterpolo, entre otros deportes.

Formalmente, una variable aleatoria X sigue una distribución de Poisson con parámetro $\lambda > 0$ si:

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots$$

donde λ representa el número de veces que se espera que ocurra el evento o fenómeno estudiado durante un intervalo dado.

En el contexto deportivo, λ puede interpretarse como el número de goles que se espera que anote un equipo en un encuentro.

2.1.1. Metodología general

Como se ha mencionado previamente, la distribución de Poisson ha sido ampliamente utilizada en la predicción de resultados deportivos, especialmente en disciplinas donde el número de anotaciones por encuentro es relativamente bajo. Uno de los primeros trabajos destacados en este ámbito es el de Maher (1982), quien lo aplicó al fútbol, modelando los goles de cada equipo enfrentado en un partido como variables aleatorias independientes con distribución de Poisson, y cuyas medias dependían de parámetros asociados al rendimiento ofensivo y defensivo de los equipos, así como de la ventaja de jugar en casa.

Partiendo de esta formulación, en esta sección se presenta una generalización del modelo que puede aplicarse a cualquier deporte con estructuras similares, como hockey, fútbol sala, balonmano o waterpolo. El objetivo es establecer una metodología general que permita, a partir de parámetros estructurales estimables, predecir el número de anotaciones por equipo en un enfrentamiento determinado.

La idea central consiste en modelar el número de anotaciones realizadas por cada competidor en un partido determinado mediante una variable aleatoria con distribución de Poisson, asumiendo independencia entre los goles de ambos oponentes. Así, para un enfrentamiento cualquiera entre dos equipos i y j se definen:

- X_{ij} como el número de goles anotados por el equipo local (i):

$$X_{ij} \sim \text{Poisson}(\alpha_i \beta_j \gamma)$$

- Y_{ij} como el número de goles anotados por el equipo visitante (j):

$$Y_{ij} \sim \text{Poisson}(\alpha_j \beta_i)$$

Los parámetros implicados en estas expresiones son los siguientes:

- α_i representa la fortaleza/capacidad ofensiva del equipo i .

- β_j representa la fortaleza/capacidad defensiva del equipo j (cuanto más bajo, mejor defensa).
- γ refleja la ventaja de jugar en casa (si $\gamma > 1$, el equipo local tiene una ventaja sistemática). Esta componente resulta especialmente relevante en deportes como el fútbol, pero también puede observarse en otras disciplinas, donde el entorno local puede influir en el rendimiento del equipo anfitrión, debido a factores como el conocimiento del terreno, menor fatiga por desplazamiento, apoyo del público, etc.

La probabilidad de cada posible resultado se calcula como:

$$P(X_{ij} = x, Y_{ij} = y) = \frac{\lambda^x e^{-\lambda}}{x!} \frac{\mu^y e^{-\mu}}{y!} \quad x, y = 0, 1, 2, \dots$$

donde $\lambda = \alpha_i \beta_j \gamma$ es el número esperado de anotaciones del equipo local. Mientras que $\mu = \alpha_j \beta_i$ es el número esperado de goles del equipo visitante.

Dado que las habilidades ofensivas y defensivas de los equipos son parámetros desconocidos, es necesario estimarlos a partir de los datos observados. Para ello, se requiere una muestra en la que cada observación corresponda a un único partido, y en la que se recojan, al menos, las siguientes variables: equipo local, equipo visitante, goles anotados por el equipo local y goles anotados por el equipo visitante.

Sea entonces una muestra compuesta por N partidos con sus respectivos resultados, donde N representa el tamaño muestral, y sea n el número de equipos distintos que participan en dicha muestra. Asumiendo independencia entre las anotaciones de ambos oponentes en cada encuentro, la función de verosimilitud correspondiente para el conjunto de N partidos viene dada por:

$$L(\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n, \gamma) = \prod_{k=1}^N \frac{\lambda_k^{x_k} e^{-\lambda_k}}{x_k!} \cdot \frac{\mu_k^{y_k} e^{-\mu_k}}{y_k!} = \prod_{k=1}^N \frac{(\alpha_i \beta_j \gamma)^{x_k} e^{-(\alpha_i \beta_j \gamma)}}{x_k!} \cdot \frac{(\alpha_j \beta_i)^{y_k} e^{-(\alpha_j \beta_i)}}{y_k!}$$

donde x_k y y_k son los goles observados para el equipo local (i) y visitante (j), respectivamente, en el partido k . De igual manera $\lambda_k = \alpha_i \beta_j \gamma$ y $\mu_k = \alpha_j \beta_i$ representan el número esperado de goles anotados por cada equipo en ese encuentro.

Dado que x_k y y_k son datos fijos observados y el objetivo de la función de verosimilitud es su maximización con respecto a los parámetros λ_k y μ_k , los términos constantes del denominador pueden omitirse. De este modo, la función a maximizar queda expresada como:

$$L(\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n, \gamma) = \prod_{k=1}^N \lambda_k^{x_k} e^{-\lambda_k} \cdot \mu_k^{y_k} e^{-\mu_k} = \prod_{k=1}^N (\alpha_i \beta_j \gamma)^{x_k} e^{-(\alpha_i \beta_j \gamma)} \cdot (\alpha_j \beta_i)^{y_k} e^{-(\alpha_j \beta_i)}$$

A partir de la maximización de esta última función se obtienen los estimadores de máxima verosimilitud de los parámetros del modelo, esto es, de las habilidades ofensivas y defensivas de cada equipo, además del parámetro que representa la ventaja de jugar en casa: $\hat{\gamma}$, $\hat{\alpha}_i$, $\hat{\beta}_i$, $\forall i = 1, \dots, n$. Se estiman un total de $2n + 1$ parámetros.

Una vez estimados los parámetros del modelo, es posible utilizarlos para intentar predecir el número de goles de ambos equipos en futuros partidos.

2.1.2. Adaptación al fútbol

El modelo descrito se adapta de forma natural al caso del fútbol profesional, donde cada partido enfrenta a un equipo local contra un equipo visitante y el número de goles anotados por cada uno es una variable discreta no negativa. La formulación planteada permite modelar los goles de ambos equipos como variables de Poisson independientes, cuya media depende de las fortalezas ofensiva y defensiva de cada conjunto, así como del posible efecto de jugar en casa.

Para llevar a cabo el modelo, se utiliza un conjunto de datos en el que cada observación representa un único partido disputado. Para cada encuentro se registran las siguientes variables: equipo local, equipo visitante, número de goles anotados por el equipo local y número de goles anotados por el equipo visitante. Esta información permite construir las variables necesarias para estimar los parámetros del modelo.

En este trabajo, se aplicará el modelo a datos correspondientes a partidos de la Primera División española, utilizando como muestra todos los encuentros disputados durante las temporadas 2018/2019 a 2022/2023. A partir de las estimaciones de los parámetros estructurales, se generarán predicciones del número de goles esperados en los partidos correspondientes a la temporada 2023/2024. Los datos utilizados han sido obtenidos de la plataforma Football-Data.co.uk (2025), que proporciona resultados históricos y estadísticas detalladas de los partidos de ligas profesionales europeas.

La implementación práctica y los resultados obtenidos, así como su posible aplicación a una estrategia de apuestas basada en goles anotados, se desarrollarán en el siguiente capítulo.

2.2. Modelo 2: Poisson con independencia y ponderación temporal

El modelo de Poisson con independencia, presentado en la sección anterior, asume que todos los partidos de la muestra tienen la misma relevancia a la hora de estimar los parámetros ofensivos y defensivos de los equipos. Sin embargo, en contextos reales, es razonable suponer que el rendimiento reciente de los equipos es más representativo que el mostrado en temporadas anteriores o en el inicio de la competición.

Con el objetivo de incorporar esta variabilidad temporal, se introduce una ponderación en la función de verosimilitud que otorga mayor peso a los partidos más recientes. Este enfoque fue propuesto por Dixon and Coles (1997) en su artículo *Modelling Association Football Scores and Inefficiencies in the Football Betting Market*, como una extensión del modelo clásico de Maher (1982), y permite reflejar mejor el estado de forma actual de los equipos, ajustando la contribución de cada partido en función del momento en el que tuvo lugar.

El resto del modelo se mantiene igual en su estructura. Se sigue asumiendo independencia entre las anotaciones de ambos conjuntos y se conserva la formulación de los parámetros ofensivos, defensivos y la ventaja de jugar en casa. A continuación, se desarrolla la metodología de esta extensión.

2.2.1. Metodología general

Supongamos de nuevo que se tiene una muestra de N partidos y sea n el número de equipos incluidos en la muestra. Para incorporar los pesos temporales en el modelo y que los parámetros de ataque y defensa de los equipos se vayan ajustando en función de su rendimiento reciente, se define la función de pseudo-verosimilitud ponderada en un instante de tiempo t como:

$$\begin{aligned} L_t(\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n, \gamma) &= \prod_{k \in A_t} \left[(\lambda_k)^{x_k} e^{-\lambda_k} (\mu_k)^{y_k} e^{-\mu_k} \right]^{\phi(t-t_k)} \\ &= \prod_{k \in A_t} \left[(\alpha_i \beta_j \gamma)^{x_k} e^{-(\alpha_i \beta_j \gamma)} (\alpha_j \beta_i)^{y_k} e^{-(\alpha_j \beta_i)} \right]^{\phi(t-t_k)} \end{aligned}$$

donde:

- El tiempo t está medido en días.
- t_k es el instante (día) en el que el partido k fue jugado. Se supone que el primer partido de la muestra fue jugado en el instante $t_0 = 0$.
- A_t es el conjunto de partidos jugados antes de t . $A_t = \{k : t_k < t\}$.
- $\phi(t - t_k)$ es una función exponencial de ponderación que decrece a medida que el partido k es más antiguo.

Para poder añadir esta función de ponderación, es necesario que el conjunto de datos recoja, además de los goles anotados por cada equipo, la fecha exacta en la que se disputó cada partido, de forma que pueda calcularse el tiempo transcurrido desde entonces.

La cuestión ahora radica en la elección específica de la función $\phi(t)$. En este trabajo se adopta la función exponencial decreciente $\phi(t) = e^{-\theta \cdot t}$, tal como proponen Dixon and Coles (1997) para modelar resultados de fútbol.

Se tiene que θ forma parte directamente de la función de pseudo-verosimilitud ponderada, y su valor afecta al peso que se da a cada observación en función de su antigüedad. Por tanto, se considera un parámetro adicional a estimar junto con el resto de parámetros, permitiendo así al propio modelo determinar el grado de importancia que debe asignarse a los partidos más recientes frente a los más antiguos. Entonces la log-verosimilitud ponderada depende ahora también de θ , y se denota como $L_t(\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n, \gamma, \theta)$

Mediante la maximización de dicha función, se obtienen los estimadores de máxima verosimilitud del modelo: $\hat{\gamma}, \hat{\theta}, \hat{\alpha}_i, \hat{\beta}_i$, con $i = 1, \dots, n$.

Una vez estimados los parámetros del modelo, este puede emplearse para generar predicciones del número esperado de goles que anotará cada equipo en futuros encuentros.

2.2.2. Adaptación al fútbol

El modelo de Poisson con independencia y ponderación temporal se integra de manera directa al caso del fútbol profesional. A diferencia del modelo simple con independencia, esta versión incorpora una función de ponderación decreciente que otorga mayor relevancia

a los partidos más recientes, permitiendo capturar mejor la evolución del rendimiento de los equipos a lo largo del tiempo.

Se necesita la misma estructura de datos que en el modelo anterior, con el añadido de una variable que recoja la fecha de disputa de cada partido. Esto permite aplicar la función de ponderación sobre el tiempo transcurrido y ajustar los parámetros ofensivos y defensivos de los equipos teniendo en cuenta la antigüedad de cada observación.

El modelo se entrena de forma análoga al anterior, utilizando los partidos de la Primera División española disputados entre las temporadas 2018/2019 y 2022/2023, para posteriormente generar predicciones sobre la temporada 2023/2024.

Al igual que antes, la puesta en práctica y los resultados obtenidos tras su aplicación dentro de una estrategia de apuestas centrada en el número de goles, se abordarán en el siguiente capítulo.

2.3. Modelo 3: Poisson bivariado

En determinadas situaciones reales, no es lógico considerar independencia entre dos variables aleatorias que siguen una distribución de Poisson. En este escenario, es necesario recurrir a una distribución que contemple la correlación entre ambas variables. Una solución es la distribución de Poisson bivariada, la cual permite modelar conjuntamente dos variables discretas cuya relación se genera a través de una componente común.

Definición: Sean $Z_1 \sim \text{Poisson}(\lambda_1)$, $Z_2 \sim \text{Poisson}(\lambda_2)$, $Z_3 \sim \text{Poisson}(\lambda_3)$ variables aleatorias independientes entre sí. Definimos las variables aleatorias $X = Z_1 + Z_3$ e $Y = Z_2 + Z_3$. Entonces, el vector aleatorio (X, Y) sigue una **distribución de Poisson bivariada** de parámetros $\lambda_1, \lambda_2, \lambda_3$:

$$(X, Y) \sim BP(\lambda_1, \lambda_2, \lambda_3)$$

La función de probabilidad conjunta de una distribución bivariada de Poisson viene dada por:

$$\begin{aligned} P(X = x, Y = y) &= e^{-(\lambda_1 + \lambda_2 + \lambda_3)} \sum_{k=0}^{\min(x, y)} \frac{\lambda_3^k \lambda_1^{x-k} \lambda_2^{y-k}}{k! (x-k)! (y-k)!} \\ &= e^{-(\lambda_1 + \lambda_2 + \lambda_3)} \cdot \frac{\lambda_1^x}{x!} \cdot \frac{\lambda_2^y}{y!} \sum_{k=0}^{\min(x, y)} \binom{x}{k} \binom{y}{k} k! \left(\frac{\lambda_3}{\lambda_1 \lambda_2} \right)^k, \quad x, y = 0, 1, 2, \dots \end{aligned}$$

La suma va desde $k = 0$ hasta $\min(x, y)$ porque k representa los posibles valores que puede tomar la parte común Z_3 .

Proposición: Algunas propiedades fundamentales de la mencionada distribución son las descritas a continuación:

1. $X \sim \text{Poisson}(\lambda_1 + \lambda_3)$. Por lo que $E[X] = \lambda_1 + \lambda_3$.
2. $Y \sim \text{Poisson}(\lambda_2 + \lambda_3)$. Por lo que $E[Y] = \lambda_2 + \lambda_3$.

3. $Cov(X, Y) = \lambda_3$, es decir, Z_3 introduce la dependencia entre las dos variables a través de λ_3 .

Demostración: Sabemos que $X = Z_1 + Z_3$ e $Y = Z_2 + Z_3$, donde $Z_1 \sim \text{Poisson}(\lambda_1)$, $Z_2 \sim \text{Poisson}(\lambda_2)$, $Z_3 \sim \text{Poisson}(\lambda_3)$ son independientes entre sí, por lo que se obtiene de manera directa las distribuciones y esperanzas de X e Y , y además:

$$Cov(X, Y) = Var(Z_3) = \lambda_3$$

□

2.3.1. Metodología general

Como ya se ha comentado, en el ámbito deportivo la distribución de Poisson ha sido ampliamente aceptada como un enfoque simple para modelar la distribución del número de goles en deportes que involucran a dos equipos competidores, asumiendo que son independientes. No obstante, investigaciones previas (Maher (1982), Dixon and Coles (1997)) han demostrado que existe una correlación (relativamente baja) entre el número de goles de ambos oponentes.

En este escenario, la distribución de Poisson bivariada permite tener en cuenta esta dependencia, ofreciendo así mejoras como una mejor predicción del número de empates en partidos, un problema común en modelos independientes. Este enfoque fue formalizado y aplicado al análisis de resultados deportivos por Karlis and Ntzoufras (2003), quienes proponen un modelo bivariado flexible que incorpora parámetros ofensivos, defensivos y de covarianza entre los goles de los equipos.

A continuación, se describe cómo implementar esta distribución para modelar resultados deportivos.

Se definen las variables aleatorias:

- X como el número de goles anotados por el equipo local en un determinado partido.
- Y como el número de goles anotados por el equipo visitante en dicho partido.

Suponemos entonces que las v.a. X e Y siguen conjuntamente una distribución de Poisson bivariada $BP(\lambda_1, \lambda_2, \lambda_3)$ con función de probabilidad conjunta dada por:

$$P_{X,Y}(x, y) = P(X = x, Y = y) = e^{-(\lambda_1 + \lambda_2 + \lambda_3)} \frac{\lambda_1^x \lambda_2^y}{x! y!} \sum_{k=0}^{\min(x,y)} \binom{x}{k} \binom{y}{k} k! \left(\frac{\lambda_3}{\lambda_1 \lambda_2} \right)^k$$

Marginalmente, cada variable sigue una distribución de Poisson con $E(X) = \lambda_1 + \lambda_3$ y $E(Y) = \lambda_2 + \lambda_3$. Es decir, el número esperado de anotaciones del equipo local en un partido concreto es $\lambda_1 + \lambda_3$, mientras que el número de goles esperado del equipo visitante viene dado por $\lambda_2 + \lambda_3$. Además, la covarianza entre X e Y es $Cov(X, Y) = \lambda_3$, por lo que λ_3 mide el grado de dependencia entre las dos variables.

Una interpretación natural de los parámetros de este modelo de Poisson bivariado es que λ_1 y λ_2 reflejan la capacidad de anotación de cada equipo en el partido, mientras que λ_3 se refiere a las condiciones del juego.

Al igual que en los dos modelos anteriores, λ_1, λ_2 y λ_3 son funciones, a su vez, de parámetros generales y relativos a los equipos. Sea entonces $(X, Y) \sim BP(\lambda_1, \lambda_2, \lambda_3)$, se definen los parámetros del modelo considerando lo siguiente:

$$\log(\lambda_1) = \mu + \text{home} + \text{att}_h + \text{def}_g$$

$$\log(\lambda_2) = \mu + \text{att}_g + \text{def}_h$$

$$\log(\lambda_3) = \beta^{cte} + \gamma_1 \beta_h^{home} + \gamma_2 \beta_g^{away}$$

donde:

- μ es un parámetro constante.
- home es el parámetro que representa el efecto de jugar en casa.
- h y g denotan el equipo local y el visitante, respectivamente.
- att_i y def_i son parámetros que encapsulan las habilidades ofensivas y defensivas del equipo i .
- La covarianza λ_3 es función de los parámetros descritos a continuación. β^{cte} es un parámetro constante y β_h^{home} y β_g^{away} son parámetros que dependen del equipo local y visitante cuando juegan de local y visitante, respectivamente. Es decir, generalizando, cada equipo tiene un parámetro β^{home} que actúa cuando juega como local y un parámetro β^{away} que actúa cuando juega de visitante. Por su parte, γ_1 y γ_2 son indicadores binarios tales que cuando $\gamma_1 = \gamma_2 = 0$ se asume que la covarianza es constante, si $(\gamma_1, \gamma_2) = (1, 0)$ se considera que la covarianza depende solo del equipo local, y así sucesivamente. γ_1 y γ_2 no son parámetros a estimar, sino que se eligen para definir la estructura de covarianza deseada.

El parámetro λ_3 puede interpretarse como un efecto aleatorio que actúa aditivamente sobre la media marginal y refleja las condiciones del juego.

Para la estimación de los parámetros se requiere una muestra en la que cada observación corresponda a un único partido, y en la que se recojan, al menos, las siguientes variables: equipo local, equipo visitante, goles anotados por el equipo local y goles anotados por el equipo visitante. Suponiendo que tenemos una muestra de N partidos con sus respectivos resultados $(X_k, Y_k) \sim BP(\lambda_{1k}, \lambda_{2k}, \lambda_{3k})$, $k = 1, \dots, N$, de la función de probabilidad conjunta anterior se deriva la siguiente función de verosimilitud:

$$\mathcal{L}(\lambda_{1k}, \lambda_{2k}, \lambda_{3k}) = \prod_{k=1}^N \left[e^{-(\lambda_{1k} + \lambda_{2k} + \lambda_{3k})} \frac{\lambda_{1k}^{x_k} \lambda_{2k}^{y_k}}{x_k! y_k!} \sum_{r=0}^{\min(x_k, y_k)} \binom{x_k}{r} \binom{y_k}{r} r! \left(\frac{\lambda_{3k}}{\lambda_{1k} \lambda_{2k}} \right)^r \right]$$

Al igual que en el Modelo 2, en esta formulación se incorpora una función de ponderación temporal decreciente $\phi(t) = e^{-\theta \cdot t}$, que asigna mayor peso a los partidos más recientes. De este modo, las observaciones más actuales influyen más en la estimación de los parámetros del modelo, lo cual es especialmente útil en este contexto, donde el rendimiento de los equipos varía a lo largo del tiempo y suele estar marcado por rachas, siendo fundamental capturar su estado de forma más reciente. Por tanto, la verosimilitud

en un instante de tiempo t viene dada por:

$$\mathcal{L}_t(\lambda_{1k}, \lambda_{2k}, \lambda_{3k}) = \prod_{k \in A_t} \left[e^{-(\lambda_{1k} + \lambda_{2k} + \lambda_{3k})} \frac{\lambda_{1k}^{x_k} \lambda_{2k}^{y_k}}{x_k! y_k!} \sum_{r=0}^{\min(x_k, y_k)} \binom{x_k}{r} \binom{y_k}{r} r! \left(\frac{\lambda_{3k}}{\lambda_{1k} \lambda_{2k}} \right)^r \right]^{\phi(t-t_k)}$$

donde:

- El tiempo t está medido en días.
- t_k es el instante (día) en el que el partido k fue jugado. Se supone que el primer partido de la muestra fue jugado en el instante $t_0 = 0$.

Tomando logaritmo transformamos la verosimilitud en una log-verosimilitud:

$$\begin{aligned} \log \mathcal{L}_t(\lambda_{1k}, \lambda_{2k}, \lambda_{3k}) = \sum_{k \in A_t} \phi(t - t_k) \cdot & \left[-(\lambda_{1k} + \lambda_{2k} + \lambda_{3k}) + x_k \log \lambda_{1k} + y_k \log \lambda_{2k} \right. \\ & - \log(x_k!) - \log(y_k!) \\ & \left. + \log \left(\sum_{r=0}^{\min(x_k, y_k)} \binom{x_k}{r} \binom{y_k}{r} r! \left(\frac{\lambda_{3k}}{\lambda_{1k} \lambda_{2k}} \right)^r \right) \right] \end{aligned}$$

A continuación, se describen los parámetros $\lambda_{1k}, \lambda_{2k}, \lambda_{3k}$ definidos para cada partido k , con el objetivo de clarificar la notación empleada en la expresión de la log-verosimilitud:

$$\log(\lambda_{1k}) = \mu + \text{home} + \text{att}_{h_k} + \text{def}_{g_k}$$

$$\log(\lambda_{2k}) = \mu + \text{att}_{g_k} + \text{def}_{h_k}$$

$$\log(\lambda_{3k}) = \beta^{cte} + \gamma_1 \beta_{h_k}^{home} + \gamma_2 \beta_{g_k}^{away}$$

donde la única novedad respecto a la notación anterior es que h_k y g_k representan ahora el equipo local y el equipo visitante, respectivamente, en el partido k .

A partir de la maximización de la función de log-verosimilitud previamente definida, se obtienen los estimadores de los parámetros del modelo. En total, se estiman $2n$ parámetros asociados a las habilidades ofensivas y defensivas de los n equipos considerados (uno de ataque y otro de defensa por equipo: $\hat{att}_i, \hat{def}_i, \forall i = 1, \dots, n$), además de un parámetro general $\hat{\mu}$, el parámetro $\hat{home}$, el parámetro $\hat{\beta}^{cte}$, y según la especificación del modelo (es decir, dependiendo de los valores de γ_1 y γ_2) hasta n parámetros adicionales $\hat{\beta}_i^{home}$ y/o n parámetros $\hat{\beta}_i^{away}$. También ha de estimarse el parámetro $\hat{\theta}$ de la función de ponderación exponencial. Suponiendo la elección $(\gamma_1, \gamma_2) = (1, 1)$, se han de estimar un total de $2n + 1 + 1 + 1 + (n + n) + 1 = 4n + 4$ parámetros, siendo n el número de equipos distintos presentes en la muestra de partidos.

Cabe destacar que el número de anotaciones esperadas del equipo local en un partido k viene dado por $E(X_k) = \lambda_{1k} + \lambda_{3k}$, y el número esperado de goles del equipo visitante para ese mismo partido es $E(Y_k) = \lambda_{2k} + \lambda_{3k}$.

2.3.2. Adaptación al fútbol

El modelo de Poisson bivariado se ajusta de forma natural al contexto del fútbol profesional. A diferencia de modelos que asumen independencia entre los goles de ambos

equipos, esta formulación permite capturar una posible dependencia o correlación entre los goles del equipo local y del visitante, a través del término de covarianza específico para cada encuentro descrito en la explicación general del método. Las medias de las distribuciones de goles se modelan en función de las habilidades ofensivas y defensivas de los equipos implicados, así como del efecto de jugar en casa y de un parámetro constante, mientras que el término de covarianza puede depender de características del partido o de los equipos, según la especificación adoptada.

En este trabajo, se ha usado la especificación dada por $\gamma_1 = \gamma_2 = 1$, por lo que la covarianza depende tanto del equipo local como del visitante. Se emplean los mismos datos que en el modelo anterior para estimar los parámetros y generar predicciones sobre los partidos de la temporada 2023/2024.

Los resultados obtenidos y su aplicación dentro de la estrategia de apuestas se presentarán, como en los modelos anteriores, en el siguiente capítulo.

2.4. Modelo 4: Random Forest de regresión

Los bosques aleatorios (Random Forest) son una técnica de aprendizaje automático que combina múltiples árboles de decisión para mejorar la precisión de las predicciones y reducir el riesgo de sobreajuste. A diferencia de los árboles individuales, que generalmente presentan una alta varianza y pueden ser sensibles a pequeñas variaciones en los datos, los bosques aleatorios construyen un conjunto de árboles entrenados sobre distintas muestras aleatorias del conjunto de entrenamiento, y promedian sus predicciones para obtener un resultado más robusto.

Para entrenar un modelo de este tipo, se requiere un conjunto de datos de entrenamiento que contenga tanto la variable objetivo Y , como un conjunto de variables explicativas $X_1, \dots, X_p$. El algoritmo construye B árboles de decisión a partir de B muestras bootstrap (una para cada árbol), que son muestras obtenidas de la original mediante el muestreo con repetición. En la construcción de estos árboles, cada vez que se va a realizar una división de un nodo, no se realiza seleccionando el "mejor" predictor en el conjunto total de p variables predictoras, sino que se utiliza una muestra aleatoria de $\mathbf{m}$ ($m \leq p$) variables predictoras.

Los parámetros B y m se pueden seleccionar a partir de técnicas de validación cruzada, pero valores comunes para problemas de regresión son $B \in [100, 1000]$ y $m \approx p/3$.

En el caso de regresión, para una observación con vector de variables explicativas $\underline{x} = (X_1 = x_1, \dots, X_p = x_p)$, cada árbol genera una predicción numérica de la variable objetivo Y , y la predicción final del modelo es el promedio de todas las predicciones individuales. Esta estrategia permite reducir la varianza del modelo y mejora su capacidad de generalización.

La predicción final para una observación con vector de entrada $\underline{x}$ se calcula como:

$$\hat{Y} = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(\underline{x})$$

donde $\hat{f}_b(\underline{x})$ es la predicción del árbol b -ésimo.

2.4.1. Metodología general

En el contexto deportivo, y concretamente en deportes donde cada partido enfrenta a dos equipos, el objetivo principal de este modelo es predecir el número de goles que anotará cada conjunto en un encuentro en función de una serie de variables predictoras. Este enfoque se inspira en el trabajo de Schauburger and Groll (2018), quienes aplican modelos de random forest tanto de regresión como de clasificación para predecir resultados de fútbol internacional, utilizando el primero para estimar el número de goles esperados y el segundo para predecir el resultado (victoria, empate o derrota) en el Mundial de 2018.

Para ello, se necesita un conjunto de datos en el que cada observación represente un partido, lo cual implica que se disponga de dos variables objetivo por registro: el número de goles marcados por el equipo local (Y^H) y por el equipo visitante (Y^A).

Además de las dos variables objetivo mencionadas, cada observación (partido) requiere de varias variables predictoras referentes a los equipos con potencial influencia en el resultado de los encuentros. Para cada equipo participante, los mencionados predictores, que supondremos que son variables numéricas, deben ser observados antes del inicio del partido.

Se tiene entonces una variable objetivo bidimensional $Y = (Y^H, Y^A)$ y un conjunto de p variables predictoras ($X_1, \dots, X_p$) medidas para cada equipo. Resultando en conjunto de datos donde en cada registro se miden las siguientes variables:

$$\mathbf{Y}^H, \mathbf{Y}^A, X_1^H, \dots, X_p^H, X_1^A, \dots, X_p^A \quad , \quad \text{donde:}$$

- Y^H, Y^A representan el número de anotaciones del equipo local y visitante, respectivamente.
- X_i^H ($i = 1, \dots, p$) representa la variable predictora i medida para el equipo local.
- X_i^A ($i = 1, \dots, p$) representa la variable predictora i medida para el equipo visitante.

Con el fin de convertir el problema en una regresión con variable objetivo unidimensional, se descompone cada observación (partido) en dos registros distintos, uno por cada equipo, con su respectivo número de goles anotados como respuesta. Además, para evitar duplicar las variables predictoras, ya que se refieren a las mismas características pero medidas para cada uno de los dos equipo enfrentados, estas se reformulan en forma de diferencia entre ambos equipos, lo que permite capturar la relación relativa entre sus características. El resultado es el siguiente esquema:

- Equipo local: $\mathbf{Y}^H, X_1^H - X_1^A, \dots, X_p^H - X_p^A$
- Equipo visitante: $\mathbf{Y}^A, X_1^A - X_1^H, \dots, X_p^A - X_p^H$

Este tratamiento no solo permite considerar una única variable objetivo por observación, sino que también incorpora la comparación entre ambos equipos como elemento clave en la predicción del número de goles.

Se construye un número de árboles B . Para cada observación, se generan B predicciones, una por cada árbol del bosque, a partir de las covariables disponibles. La predicción final se obtiene como el promedio de las B predicciones individuales.

Con el objetivo de optimizar el rendimiento del modelo, se puede emplear validación cruzada para seleccionar el valor óptimo de los hiperparámetros B y $mtry$, que determina cuántas variables se seleccionan aleatoriamente en cada nodo para evaluar posibles divisiones. Este procedimiento permite comparar distintas combinaciones de B y $mtry$ y elegir aquella que minimiza el error de predicción medio en los subconjuntos de validación.

Sin embargo, las estimaciones puntuales del número de goles no pueden utilizarse directamente para predecir el resultado de partidos individuales, pues la variable respuesta se modela como continua, lo que puede generar predicciones no enteras para el número de goles de cada equipo en un encuentro. Por ejemplo, se podría obtener una predicción de 2.3 goles para el local y 1.1 goles para el visitante. Para solventar esta limitación, se interpretará cada valor predicho como una estimación del parámetro λ (media) de una distribución de Poisson. Así, dentro de un mismo partido, se asumirán dos distribuciones de Poisson independientes (una para cada equipo) y se utilizarán para generar predicciones probabilísticas del número de goles de cada competidor.

2.4.2. Adaptación al fútbol

El random forest de regresión se amolda perfectamente al caso del fútbol profesional. En este contexto, se utilizan variables predictoras cuantitativas asociadas al rendimiento previo de ambos equipos para estimar los goles que marcarán en el encuentro.

Al igual que los modelos previos, éste se ha aplicado a la Primera División española de fútbol con el objetivo de predecir los goles de los partidos correspondientes a la temporada 2023/2024. Para ello, se entrena utilizando resultados históricos de las temporadas 2018/2019 a 2021/2022. Posteriormente, se evalúa su rendimiento sobre los partidos disputados durante la temporada 2022/2023, que se reserva como conjunto test. Una vez entrenado y validado el modelo, se emplea para realizar las predicciones sobre la temporada 2023/2024.

En cuanto a los hiperparámetros seleccionados, se ha fijado el número de árboles del bosque aleatorio en $B = 1000$, un valor habitual que ofrece un buen equilibrio entre estabilidad y coste computacional en este trabajo en concreto, mientras que el valor óptimo del parámetro $mtry$ se ha elegido mediante validación cruzada.

Dado que se pretende obtener predicciones de todos los partidos de una temporada completa, la mayoría de covariables asociadas a los equipos se calculan justo antes del inicio de dicha temporada y se mantienen fijas a lo largo de toda ella, por lo que sus valores varían de una temporada a otra. Entre las variables consideradas para cada equipo se incluyen:

- Pos: Posición en la tabla clasificatoria en la que quedó el equipo en la liga anterior.
- Pts: Número de puntos conseguidos en la liga anterior.
- GF: Número de goles marcados en la liga anterior.
- GC: Número de goles recibidos en la liga anterior.

- **ValorMercado**: Valor de mercado de la plantilla justo al acabar el período de fichajes de verano, es decir, prácticamente al inicio de la temporada. Medida en millones de €.
- **EdadMedia**: Edad media de la plantilla al inicio de la temporada.
- **Gasto**: Dinero invertido en fichajes durante el mercado de fichajes de verano. Medida en millones de €.

Todas estas variables han sido recopiladas a partir de información procedente de la página web Transfermarkt (Transfermarkt, 2025), organizadas y estructuradas en un conjunto de datos propio.

Además, se incorpora como covariable adicional las puntuaciones ELO de los clubes, las cuales representan la fortaleza de los equipos en un momento determinado. Este tipo de puntuaciones han demostrado ser útiles para modelar y predecir resultados en deportes como el fútbol, tal como se expone en el trabajo de Hvattum and Arntzen (2010), lo que motivó su incorporación como variable explicativa en este estudio. Esta variable sí varía a lo largo de la temporadas, pues se actualiza los días 1 y 15 de cada mes dependiendo de los resultados recientes del equipo. El dataset que contiene dichas puntuaciones ELO ha sido extraído del repositorio de GitHub *xgabora/Club-Football-Match-Data-2000-2025* (xgabora, 2025), el cual combina puntuaciones Elo procedentes de *ClubElo* (ClubElo, 2025) junto con datos de partidos proporcionados por *Football-Data* (Football-Data.co.uk, 2025), para generar una variable que mida el poderío de los equipos.

Tabla 2.1: Resumen de variables predictoras utilizadas en el modelo

Variable	Tipo	Fuente	Descripción
Pos	Numérica	Transfermarkt	Posición en la tabla en la temporada anterior.
Pts	Numérica	Transfermarkt	Puntos conseguidos en la temporada anterior.
GF	Numérica	Transfermarkt	Goles a favor en la temporada anterior.
GC	Numérica	Transfermarkt	Goles en contra en la temporada anterior.
ValorMercado	Numérica	Transfermarkt	Valor de mercado de la plantilla al inicio de la temporada (M€).
EdadMedia	Numérica	Transfermarkt	Edad media de la plantilla al inicio de la temporada.
Gasto	Numérica	Transfermarkt	Gasto en fichajes durante el verano anterior (M€).
Elo	Numérica y dinámica	GitHub (xgabora)	Puntuación Elo actualizada dos veces al mes, refleja el nivel reciente del equipo.

Cabe recordar que, tal como se explicó en la metodología general, cada partido se descompone en dos observaciones, una por cada equipo, donde la variable objetivo es el número de goles anotados por ese equipo, facilitando así el uso de un modelo de regresión

unidimensional. Para cada una de estas observaciones, las variables predictoras se calculan como la diferencia entre los valores del equipo objetivo y los del rival, lo que permite capturar la relación relativa entre sus características sin duplicar información.

Por otro lado, el conjunto de datos empleado también incluye variables de identificación del partido, como la fecha de disputa, el equipo local y el equipo visitante, que no se utilizan directamente para entrenar el modelo, pero permiten organizar e identificar los encuentros de forma precisa.

Como se indicó anteriormente, dado que el modelo predice valores continuos, las predicciones obtenidas para cada equipo se interpretan como valores esperados de una distribución de Poisson. Así, para cada partido se consideran dos distribuciones de Poisson independientes, una por equipo, con los parámetros obtenidos mediante el modelo de Random Forest, lo que permite generar predicciones probabilísticas del número de goles.

Al igual que en los modelos anteriores, la puesta en práctica de este modelo, así como los resultados derivados de su aplicación y su utilidad potencial en contextos de predicción de goles, se detallan en el capítulo siguiente.

2.5. Modelo 5: Random Forest de clasificación

Los bosques aleatorios también pueden aplicarse en tareas de clasificación, en las que la variable objetivo es cualitativa y toma valores en un conjunto finito de clases. El objetivo en tareas de clasificación es asignar cada observación a una de dichas clases en función de sus características observadas (variables predictoras): $X_1, \dots, X_p$.

El funcionamiento del algoritmo es análogo al del modelo de regresión: se generan B árboles de decisión, cada uno entrenado sobre una muestra bootstrap del conjunto de datos. En cada división de los nodos de un árbol, la selección de la variable con la que dividir se realiza entre un subconjunto aleatorio de predictores, de tamaño $m \leq p$, en lugar de considerar todas las variables explicativas disponibles. Este enfoque introduce diversidad entre los árboles, lo cual mejora la capacidad de generalización del modelo.

A diferencia del caso de regresión, donde cada árbol produce una predicción numérica, en clasificación cada árbol genera una predicción categórica, es decir, asigna una clase concreta a la observación. La predicción final del modelo se obtiene mediante votación mayoritaria entre los B árboles:

$$\hat{Y} = \text{moda} \left(\hat{f}_1(\underline{x}), \hat{f}_2(\underline{x}), \dots, \hat{f}_B(\underline{x}) \right)$$

donde $\hat{f}_b(\underline{x})$ representa la clase asignada por el árbol b -ésimo a la observación con vector de entrada $\underline{x}$.

Al igual que en el caso de regresión, los hiperparámetros más relevantes, como el número de árboles B o el número de variables consideradas en cada división (*mtry*), pueden seleccionarse mediante técnicas de validación cruzada, en este caso optimizando métricas propias de clasificación, como la tasa de acierto (accuracy) o el log-loss. Valores comunes para problemas de clasificación son $B \in [100, 1000]$ y $m \approx \sqrt{p}$.

2.5.1. Metodología general

En este caso, el objetivo del modelo no es estimar el número de anotaciones, sino predecir directamente el resultado final del partido como una de tres categorías posibles: victoria local, empate o victoria visitante. Este enfoque de clasificación multiclase permite asignar a cada partido una etiqueta cualitativa $Y \in \{1, X, 2\}$ en función del desenlace observado. Esta formulación también se basa en el mencionado trabajo de Schauburger and Groll (2018).

Para aplicar este modelo, se requiere un conjunto de datos en el que cada observación represente un partido, junto con una serie de variables predictoras cuantitativas asociadas a los dos equipos involucrados. La variable objetivo en este caso es un único valor categórico por partido que indica su desenlace: Victoria Local, Empate o Victoria Visitante.

Se tiene entonces una variable objetivo categórica Y , que representa el desenlace del encuentro, y un conjunto de p variables predictoras $(X_1, \dots, X_p)$ medidas para cada equipo. El conjunto de datos se estructura de forma que cada registro (partido) contiene la siguiente información:

$$\mathbf{Y}, X_1^H, \dots, X_p^H, X_1^A, \dots, X_p^A \quad , \quad \text{donde:}$$

- $Y \in \{1, X, 2\}$ representa el resultado del partido: victoria local (1), empate (X) o victoria visitante (2).
- X_i^H ($i = 1, \dots, p$) corresponde a la variable predictora i medida para el equipo local.
- X_i^A ($i = 1, \dots, p$) corresponde a la misma variable i medida para el equipo visitante.

A diferencia del modelo de regresión, en este caso no es necesario descomponer cada partido en dos registros, ya que la variable objetivo Y es única por encuentro. Sin embargo, para evitar la duplicación de variables predictoras y capturar de forma eficiente las diferencias entre los equipos enfrentados, las covariables se estructuran en forma de diferencia entre los valores del equipo local y los del visitante. Este enfoque permite reflejar el contraste entre ambos conjuntos, además de ser más eficiente computacionalmente. Para cada partido, se mide:

$$\mathbf{Y}, X_1^H - X_1^A, \dots, X_p^H - X_p^A$$

Se ajusta un número de árboles B . Para cada observación, se generan B predicciones categóricas, una por cada árbol del bosque, a partir de las variables explicativas. La predicción final del modelo se obtiene mediante votación mayoritaria entre las B predicciones individuales, es decir, se asigna a cada observación la clase más frecuente entre las predicciones emitidas por los árboles.

De la misma manera que en el modelo de regresión, para optimizar el rendimiento del modelo, se puede emplear validación cruzada para seleccionar el valor óptimo de los hiperparámetros B y $mtry$. Esta técnica permite comparar distintas combinaciones de B y $mtry$ y elegir aquella que maximiza la precisión del modelo (o alguna otra métrica de clasificación) en los subconjuntos de validación.

2.5.2. Adaptación al fútbol

Este modelo se adapta fácilmente al fútbol profesional, abordando el problema como una tarea de clasificación multiclase. También se aplica a los partidos de la Primera División española, con el objetivo de predecir el desenlace de cada encuentro en términos de resultado final: victoria local, empate o victoria visitante. Aquí la variable objetivo es categórica y se representa mediante una única observación por partido, a diferencia del random forest de regresión que requería una descomposición en dos registros.

Al igual que en el modelo anterior, el conjunto de datos utilizado para entrenar el modelo incluye todos los partidos de las temporadas 2018/2019 a 2021/2022, mientras que los encuentros de la temporada 2022/2023 se reservan como conjunto test. Una vez entrenado y validado, el modelo se emplea para predecir el resultado de los partidos de la temporada 2023/2024.

En este enfoque concreto, el número de árboles del bosque se ha predefinido en $B = 500$, y el valor del hiperparámetro *mtry* se ha seleccionado por validación cruzada.

Se utilizan las mismas variables predictoras que en el caso de regresión, las cuales están asociadas al rendimiento previo de los equipos: Pos, Pts, GF, GC, ValorMercado, EdadMedia, Gasto y ELO. Se estructuran en forma de diferencia entre el equipo local y el visitante para capturar las características relativas de ambos equipos sin necesidad de duplicar información.

Esta propuesta también se implementa con fines prácticos dentro de una estrategia de apuestas deportivas, basada ya no en el número de goles, sino en la predicción directa del resultado final del encuentro (1X2). El desarrollo de esta aplicación, junto con los resultados obtenidos, se presenta en el capítulo siguiente.

2.6. Modelo 6: XGBoost de clasificación

El boosting es una técnica de ensamblado cuyo principal objetivo reside en mejorar la capacidad predictiva de métodos de aprendizaje estadístico débiles que presentan alta varianza.¹ En este trabajo se aplica a árboles de decisión para tareas de clasificación.

Boosting comparte ciertas similitudes con métodos como el bagging o los bosques aleatorios. La diferencia fundamental radica en la forma en que se entrenan. En los bosques aleatorios, los árboles se entrenan en paralelo, es decir, son completamente independientes entre sí, mientras que en el boosting se construyen secuencialmente, esto es, cada árbol se elabora teniendo en cuenta los errores cometidos por los anteriores. De esta manera, cada árbol presenta mayor atención a los casos que fueron incorrectamente clasificados en etapas previas, logrando así que poco a poco el modelo mejore globalmente su capacidad de predicción, especialmente en áreas donde no funciona bien inicialmente.

Existen varias variantes de algoritmos que implementan boosting, como AdaBoost y Gradient Boosting (IBM, 2025). En este trabajo nos centramos en Gradient Boosting, una técnica basada en la minimización de una función de pérdida diferenciable arbitraria,

¹Basado en los apuntes de clase de *Estadística Computacional II: Métodos Boosting*, Universidad de Sevilla (2024/2025), elaborados por Juan M. Muñoz Pichardo y Rafael Pino Mejías.

a partir de la aproximación del gradiente. Para problemas de clasificación multiclase, una función de pérdida diferenciable adecuada puede ser la entropía cruzada (log-loss).

Por su parte, XGBoost (Extreme Gradient Boosting) es una implementación eficiente y optimizada del algoritmo Gradient Boosting, que consigue un alto rendimiento tanto en problemas de regresión como de clasificación.

Entre las principales ventajas de XGBoost con respecto a Gradient Boosting se encuentran las descritas a continuación. XGBoost introduce términos de regularización L_1 y L_2 en la función objetivo, lo que reduce el sobreajuste. Además, se utiliza una aproximación de segundo orden de la función de pérdida con el fin de obtener un cálculo más preciso del descenso del gradiente. Cabe destacar también que XGBoost implementa un algoritmo que permite el desarrollo de los árboles de forma paralela, lo cual reduce significativamente el tiempo de cómputo.

El comportamiento de un modelo XGBoost depende de una gran cantidad de hiperparámetros. A continuación, se describen los más importantes:

- **nrounds:** número de árboles/iteraciones empleadas.
- **eta:** tasa de aprendizaje. Toma valores en el intervalo $(0,1]$. Valores pequeños suelen generalizar mejor, aunque requieren de más iteraciones.
- **max_depth:** profundidad máxima de los árboles. Valores altos permiten capturar relaciones complejas, pero también incrementan el riesgo de sobreajuste.
- **subsample:** fracción de observaciones utilizadas para entrenar cada árbol. Introduce aleatoriedad y ayuda a evitar el sobreajuste.
- **colsample_bytree:** fracción de variables utilizadas al construir cada árbol. Útil cuando una o dos variables dominan el modelo.
- **gamma:** mínimo incremento en la función objetivo necesario para realizar una partición.
- **alpha y lambda:** coeficientes de regularización L_1 y L_2 , respectivamente.
- **objective:** función objetivo. En clasificación multiclase existen principalmente dos tipos, `multi:softprob` (devuelve probabilidades) o `multi:softmax` (devuelve la clase predicha).
- **early_stopping_rounds:** número de iteraciones sin mejora significativa en el conjunto de validación tras las cuales se detiene el entrenamiento.

Para entrenar un modelo XGBoost, se necesita un conjunto de datos de entrenamiento que contenga una variable objetivo Y y una serie de variables explicativas $X_1, \dots, X_p$. El algoritmo genera secuencialmente un conjunto de n (*nrounds*) árboles de decisión, donde cada uno corrige los errores cometidos por el conjunto de árboles anteriores. Como ya se ha dicho, a diferencia de métodos como el bagging o Random Forest, los árboles no son independientes, sino que se construyen de forma aditiva para minimizar una función de pérdida.

En problemas de clasificación multiclase, como el considerado en este trabajo, XGBoost construye un árbol para cada clase, y en cada iteración actualiza sus predicciones teniendo en cuenta los errores cometidos en iteraciones anteriores. Por tanto, si se utilizan n iteraciones para un problema con K clases, el modelo entrena un total de $K \times n$ árboles. Si se emplea la opción `multi:softprob`, la predicción final para una observación con vector de entrada $\underline{x} = (X_1 = x_1, \dots, X_p = x_p)$ es un vector de probabilidades asociadas a cada clase, mientras que con `multi:softmax`, el modelo devuelve directamente la clase con mayor puntuación o probabilidad.

2.6.1. Metodología general

En este modelo, el objetivo es clasificar el resultado de un partido de fútbol en una de tres categorías posibles: victoria local, empate o victoria visitante. Se trata, por tanto, de un problema de clasificación multiclase, donde la variable objetivo Y toma valores en el conjunto $\{1, X, 2\}$. La elección de este enfoque con XGBoost surge como una extensión del modelo anterior basado en Schauburger and Groll (2018), explorando la posibilidad de aplicar técnicas de boosting en lugar de bosques aleatorios para mejorar la predicción del resultado final de los encuentros.

Para aplicar este modelo, se requiere un conjunto de datos con una estructura similar al random forest anterior. Por lo que se dispone de una variable objetivo Y que representa el resultado del encuentro, y de un conjunto de p variables predictoras $X_1, \dots, X_p$, medidas para cada equipo. De esta forma, cada partido del conjunto de datos incluye la siguiente información:

$$\mathbf{Y}, X_1^H, \dots, X_p^H, X_1^A, \dots, X_p^A$$

De la misma manera, las variables predictoras se reformulan en forma de diferencias para evitar sobrecargar el dataset y ser más eficiente:

$$\mathbf{Y}, X_1^H - X_1^A, \dots, X_p^H - X_p^A$$

Con el objetivo de optimizar el rendimiento del modelo, se emplea validación cruzada para seleccionar los valores óptimos de los hiperparámetros mencionados anteriormente, tales como *nrounds*, *eta*, *max_depth*, *gamma*, etc. Este procedimiento permite evaluar distintas combinaciones posibles y escoger aquellas que maximizan el rendimiento del modelo en los subconjuntos de validación, utilizando métricas de clasificación como la precisión global.

El modelo se entrena a partir de los hiperparámetros elegidos. En cada iteración, se construye un conjunto de árboles, uno por cada clase, que contribuye a actualizar las predicciones del modelo corrigiendo los errores cometidos en las iteraciones anteriores. Al finalizar el proceso de entrenamiento, cada observación del conjunto de datos cuenta con una predicción para cada clase, que puede interpretarse como una puntuación o probabilidad relativa.

Si se emplea la opción `multi:softprob`, el modelo devuelve un vector de probabilidades asociadas a cada una de las tres clases posibles (Victoria Local, Empate, Victoria Visitante), y la predicción final se obtiene asignando a cada observación la clase con mayor probabilidad estimada. En cambio, si se utiliza `multi:softmax`, el modelo devuelve directamente la clase predicha con mayor puntuación.

2.6.2. Adaptación al fútbol

El XGBoost de clasificación encaja perfectamente en el marco del fútbol profesional. Al igual que en el random forest de clasificación, se aplica a la primera división española para predecir los resultados finales de los partidos.

Se utilizan las mismas variables predictoras asociadas a los equipos, estructuradas de nuevo en forma de diferencias entre el equipo local y el visitante. También se mantienen los mismos conjuntos de entrenamiento y test utilizados en los dos modelos anteriores, generando predicciones para los partidos de la temporada 2023/2024.

Este modelo también se lleva a cabo en el marco de una estrategia de apuestas deportivas orientada a la predicción del resultado final del partido. El objetivo es evaluar si mejora el rendimiento del modelo Random Forest de clasificación en términos de acierto en apuestas. Los detalles sobre esta aplicación, así como los resultados obtenidos, se presentan en el siguiente capítulo.

Capítulo 3

Implementación en R

En este capítulo vamos a ver cómo se aplican en la práctica las técnicas estadísticas desarrolladas para predecir resultados en el fútbol, utilizando el lenguaje de programación R. Después de haber explicado los conceptos teóricos y metodológicos en el capítulo anterior, en este capítulo se muestra cómo convertir esas ideas en código funcional, aplicándolas a los datos de la liga española de fútbol.

Se detallará el proceso de construcción de los modelos predictivos, tanto para la estimación del número de goles como para la predicción de resultados en formato 1X2. Dichas predicciones se harán sobre los partidos de la temporada 2023/2024 de la Primera División española de fútbol. A partir de los modelos construidos, se desarrolla una aplicación práctica orientada al diseño de estrategias de apuestas deportivas. Concretamente, se emplean las predicciones generadas por los modelos para tomar decisiones de apuesta en función de dos tipos de mercado:

- **Mercado de goles totales (Over/Under 2.5 goles):** La estrategia consiste en comparar, para cada partido de la temporada 2023/2024, las probabilidades estimadas por los modelos con las probabilidades implícitas extraídas de las cuotas ofrecidas por la casa de apuestas Bet365. A partir de la estimación del número de goles anotados por cada equipo, se calcula la probabilidad de que el total de goles del encuentro sea superior (Over) o inferior (Under) a 2.5. Se decide realizar una apuesta cuando se cumplen dos condiciones simultáneas: (1) la probabilidad estimada por el modelo para el evento Over o Under es superior a 0.7, y (2) dicha probabilidad supera a la probabilidad implícita correspondiente ofrecida por la casa de apuestas. En ese caso, se apuesta una unidad monetaria al resultado favorecido por el modelo. Esta estrategia se aplica con los modelos de regresión (Modelos 1 a 4).
- **Mercado 1X2 (resultado final del partido):** Se utiliza el resultado predicho por modelos de clasificación para apostar directamente a la victoria local, empate o victoria visitante. El plan consiste en apostar una unidad monetaria en cada uno de los partidos de la temporada 2023/2024 al resultado predicho por el modelo (formato 1X2). Esta estrategia se implementa con los modelos de clasificación Random Forest y XGBoost (Modelos 5 y 6).

Para ambas estrategias, la evaluación de su rentabilidad se realiza en función de las ganancias netas acumuladas al finalizar la temporada. Además, se calcula el ROI (Return on Investment) como métrica complementaria, que mide el retorno económico (neto) obtenido por cada unidad invertida. Esta métrica permite comparar la eficacia de las distintas estrategias de forma proporcional, independientemente del número total de apuestas realizadas.

Para la elaboración de este capítulo se ha hecho uso de diversas librerías de R, necesarias para el correcto funcionamiento del código. Entre ellas se encuentran:

- `readr` y `readxl`: utilizadas para la lectura e importación de datos.
- `kableExtra`: empleada para la generación de tablas con formato profesional.
- `dplyr`: fundamental para la manipulación y transformación de datos.
- `ggplot2`: usada para generar gráficos presentables.
- `caret`: para el entrenamiento y validación de los modelos de aprendizaje automático.
- `randomForest` y `xgboost`: encargadas de desarrollar los modelos basados en Random Forest y XGBoost.

3.1. Datos y funciones

Aunque en los apartados de adaptación al fútbol de cada modelo ya se ha introducido el origen de los datos empleados, en esta sección se ofrece un resumen general de los conjuntos de datos utilizados, especificando su aplicación en los distintos modelos. Además, se describen nuevas variables relativas a las cuotas de apuestas, fundamentales para el desarrollo de las estrategias planteadas previamente.

Para todos los modelos, se ha utilizado conjuntos de datos obtenidos de la plataforma pública Football-Data.co.uk (2025), que recoge información detallada sobre los partidos de la Primera División española por temporada. En concreto, se dispone de las siguientes variables: fecha del partido, jornada, equipo local, equipo visitante, goles anotados por cada equipo y resultado final del encuentro.

Además, esta fuente proporciona información relevante sobre las cuotas ofrecidas por la casa de apuestas Bet365, por lo que se han incorporado al análisis las siguientes variables adicionales para cada partido de la temporada 2023/2024: *Cuota_Over_2.5* y *Cuota_Under_2.5*, *Cuota_Victoria_Local*, *Cuota_Empate*, *Cuota_Victoria_Visitante*.

Las dos primeras se han utilizado en los modelos de regresión que predicen el número de goles (Modelos 1 a 4), con el objetivo de evaluar el retorno económico en datos reales. Por otro lado, las cuotas asociadas al resultado final del partido se han empleado en los modelos de clasificación (Modelos 5 y 6) para calcular de nuevo el retorno económico en función de las predicciones de los resultados.

Cabe recordar que en los modelos basados en aprendizaje automático (Modelos 4 a 6), se emplea un segundo conjunto de datos centrado en características de los equipos

que actúan como variables predictoras. En este dataset se recogen las variables *Pos*, *Pts*, *GF*, *GC*, *ValorMercado*, *EdadMedia*, *Gasto*, *Elo*, las cuales ya han sido descritas en los apartados correspondientes y no se detallan nuevamente aquí.

Además de la preparación de los datos, se han creado dos funciones en R que permiten simular las estrategias de apuestas descritas. Por ejemplo, la función `apostar_goles()` evalúa si se cumplen las condiciones para realizar una apuesta en el mercado Over/Under 2,5 goles y calcula la ganancia neta correspondiente, mientras que `simular_apuesta()` realiza la simulación para apuestas en formato 1X2. Estas funciones permiten automatizar el análisis y facilitar la evaluación del rendimiento económico de cada modelo.

3.2. Poisson con independencia

3.2.1. Estimación de parámetros

A partir del modelo basado en dos distribuciones de Poisson independientes, descrito anteriormente en el capítulo 2, se procede a estimar los parámetros del modelo. Dichos parámetros dependen de las habilidades ofensivas y defensivas de los equipos. La estimación de estos parámetros se realiza de forma dinámica, jornada a jornada, utilizando todos los partidos disputados hasta la jornada inmediatamente anterior de la temporada 2023/2024, junto con los datos históricos desde la temporada 2018/2019.

Este procedimiento permite adaptar los parámetros del modelo a la evolución real de la temporada 2023/2024, ajustando las habilidades ofensivas (α) y defensivas (β) de cada equipo en función del rendimiento observado. En la siguiente tabla se muestra, a modo ilustrativo, un resumen de las habilidades estimadas de 10 equipos para la primera jornada:

Tabla 3.1: Habilidades estimadas Jornada 1 (Modelo 1)

Jornada	Equipo	α	β	γ
1	Betis	1.277	0.912	1.308
1	Girona	1.219	1.009	1.308
1	Barcelona	2.008	0.659	1.308
1	Celta	1.185	0.987	1.308
1	Villarreal	1.495	0.841	1.308
1	Eibar	0.978	0.977	1.308
1	Real Madrid	1.784	0.637	1.308
1	Vallecano	1.071	1.069	1.308
1	Ath Bilbao	1.103	0.760	1.308
1	Valencia	1.209	0.894	1.308

A continuación, se representa la evolución de la habilidad ofensiva y defensiva estimada a lo largo de las jornadas para cinco equipos seleccionados: Real Madrid, Barcelona, Atlético de Madrid, Betis y Granada. Estas gráficas permiten visualizar cómo varían las fortalezas de ataque y defensa de cada equipo durante la temporada.




Figura 3.1: Evolución de la habilidad ofensiva (Modelo 1)




Figura 3.2: Evolución de la habilidad defensiva (Modelo 1)

Se aprecia claramente que los mejores equipos (Real Madrid, FC Barcelona, Atlético de Madrid) destacan tanto por sus habilidades ofensivas, reflejadas en valores más altos del parámetro α , como por su destreza defensiva, representada por valores más bajos de β . Por otro lado, no se ven grandes variaciones en los parámetros de cada equipo a lo largo de la temporada, lo cual contrasta con los siguientes modelos, en los que se incorpora una función de ponderación temporal que otorga mayor relevancia a los partidos más recientes.

Visualizamos ahora la evolución del parámetro γ , que representa la ventaja de jugar como local. Se observa que dicho valor se mantiene prácticamente constante (alrededor de 1,30) a lo largo de las jornadas, lo cual era esperable dada la naturaleza del parámetro.




Figura 3.3: Ventaja de jugar en casa (Modelo 1)

3.2.2. Estrategia de apuestas

Recordemos que la estrategia de apuestas se basa en realizar una apuesta únicamente cuando la probabilidad estimada por el modelo para Over o Under (2,5 goles) supera el umbral de 0,7 y, además, es mayor que la probabilidad implícita ofrecida por la casa de apuestas Bet365. A continuación, se muestran los resultados obtenidos al aplicar esta estrategia sobre los partidos de la temporada 2023/2024 utilizando las predicciones generadas a través de las estimaciones de los parámetros del modelo.

Tabla 3.2: Ganancia neta (Modelo 1)

Metrica	Valor
Ganancia neta total	3.85
Numero de apuestas	37
ROI	0.1041

Los resultados muestran una ganancia neta positiva de 3,85 u.m. tras apostar en 37 partidos, lo que representa un ROI del 10,41 %. Este rendimiento sugiere que el modelo permite obtener beneficios económicos bajo la estrategia planteada.

Tabla 3.3: Apuestas ganadas vs falladas (Modelo 1)

Tipo_Apuesta	Ganada	Fallada
Over	2	0
Under	23	12

Se observa que se aciertan 25 de las 37 apuestas realizadas, lo que representa un porcentaje de acierto del 67,6 %. Esta tasa de acierto, junto con el ROI positivo previamente comentado, respalda la eficacia del plan aplicado.

Tabla 3.4: Ganancias por tipo de apuesta (Modelo 1)

Tipo_Apuesta	Apuestas	Ganancia_Total	ROI
Over	2	0.65	0.3250
Under	35	3.20	0.0914




Figura 3.4: Ganancias por tipo de apuesta (Modelo 1)

Se aprecia que las apuestas de tipo *Over*, aunque mucho menos frecuentes (2 apuestas), han arrojado un ROI considerablemente mayor que las de tipo *Under*, con un 32,5 % frente al 9,14 %. Esta diferencia de rentabilidad queda reflejada visualmente en el gráfico.

En resumen, los resultados obtenidos muestran un desempeño positivo del Modelo 1 al aplicarlo en una estrategia de apuestas basada en goles totales. A pesar de su simplicidad, el modelo logra generar ganancias netas y mantener un ROI algo superior al 10 %. En las siguientes secciones se analizarán otros modelos más complejos y sus respectivas rentabilidades económicas bajo la misma estrategia.

3.3. Poisson con independencia y ponderación temporal

3.3.1. Estimación de parámetros

Como ya se ha expuesto previamente en el capítulo 2, este modelo es esencialmente igual al anterior, con el añadido de una función de ponderación temporal que otorga mayor peso a los partidos más recientes. Esto permitirá que la estimación de habilidades ofensivas y defensivas se adapte más rápidamente a la evolución de los equipos durante la temporada.

De nuevo, la estimación de los parámetros se realiza de forma dinámica, jornada a jornada, utilizando para la estimación de los habilidades en cada jornada todos los partidos disputados hasta la jornada inmediatamente anterior de la temporada 2023/2024, junto

con los datos históricos desde la temporada 2018/2019. A continuación se muestran las habilidades estimadas de 10 equipos para la primera jornada:

Tabla 3.5: Habilidades estimadas Jornada 1 (Modelo 2)

Jornada	Equipo	α	β	γ
1	Betis	1.019	0.878	1.415
1	Girona	1.296	1.112	1.415
1	Barcelona	1.427	0.568	1.415
1	Celta	0.946	1.020	1.415
1	Villarreal	1.423	0.924	1.415
1	Eibar	0.657	1.184	1.415
1	Real Madrid	1.534	0.782	1.415
1	Vallecano	0.922	1.194	1.415
1	Ath Bilbao	0.928	0.912	1.415
1	Valencia	0.857	0.947	1.415

De forma similar al modelo anterior, se representa la evolución de la habilidad ofensiva y defensiva estimada a lo largo de las jornadas para los siguientes equipos: Real Madrid, Barcelona, Atlético de Madrid, Betis y Granada.




Figura 3.5: Evolución de la habilidad ofensiva (Modelo 2)




Figura 3.6: Evolución de la habilidad defensiva (Modelo 2)

En contraste con el modelo anterior, en este caso se observa una mayor variación de los parámetros a lo largo de la temporada, capturando de forma más eficaz las rachas positivas y negativas de los equipos. Un ejemplo claro es el Real Madrid, que se proclamó campeón con solvencia, y en ambos gráficos se detecta como se desmarca claramente de sus rivales en la lucha por el título.

El resto de parámetros estimados son:

- $\hat{\gamma} = 1,415$
- $\hat{\theta} = 0,005$

3.3.2. Estrategia de apuestas

Los resultados del plan de apuestas a partir de las predicciones de este modelo se recogen a continuación.

Tabla 3.6: Ganancia neta (Modelo 2)

Metrica	Valor
Ganancia neta total	13.56
Numero de apuestas	71
ROI	0.1910

Se observa una ganancia neta total de 13,56 unidades monetarias tras apostar en 71 partidos de la temporada 2023/2024. Esto supone un ROI del 19,10 %, que representa el retorno económico obtenido (neto) sobre el dinero total apostado.

Tabla 3.7: Apuestas ganadas vs falladas (Modelo 2)

Tipo_Apuesta	Fallada	Ganada
Over	4	18
Under	14	35

En total, se han acertado 53 de las 71 apuestas realizadas, lo que equivale a un 74,6 % de acierto. Esto indica una muy alta tasa de acierto en los partidos seleccionados por la estrategia.

Tabla 3.8: Ganancias por tipo de apuesta (Modelo 2)

Tipo_Apuesta	Apuestas	Ganancia_Total	ROI
Over	22	6.15	0.2795
Under	49	7.41	0.1512




Figura 3.7: Ganancias por tipo de apuesta (Modelo 2)

Tal como se aprecia en la tabla y el gráfico, las apuestas del tipo *Over* presentan un ROI más elevado (27,95 %) que las del tipo *Under* (15,12 %). Sin embargo, la mayor parte de las apuestas realizadas se concentran en el *Under*, donde también se obtiene una ganancia significativa.

En conclusión, los resultados obtenidos con el Modelo 2 reflejan una mejora en la rentabilidad respecto al modelo anterior. Con un ROI global del 19,10 % frente al 10,41 % del Modelo 1, se evidencia un mayor retorno económico, lo que sugiere que la incorporación de la ponderación temporal en las estimaciones puede aportar beneficios relevantes en este tipo de aplicaciones.

3.4. Poisson bivariado

3.4.1. Estimación de parámetros

Tras haber trabajado con modelos de Poisson donde los goles del equipo local y visitante se consideraban independientes (Modelos 1 y 2), en este modelo basado en la distribución de Poisson bivariada se incorpora una posible correlación entre ambos marcadores a través de un nuevo parámetro que representa la covarianza, al que denominaremos λ_3 , que a su vez es función de los parámetros β^{cte} , β^{home} , β^{away} , ya explicados en el capítulo 2. Esta dependencia puede capturar mejor ciertas dinámicas dentro de un partido.

La estructura del modelo es parecida a los anteriores, manteniendo los parámetros de habilidades ofensivas (*Ataque*), defensivas (*Defensa*) y la ventaja de jugar en casa (*Home*), además de la introducción de un nuevo parámetro constante, denominado μ , y los parámetros que forman parte de la covarianza: β^{cte} , β^{home} , β^{away} .

Los parámetros β^{cte} , β^{home} , β^{away} , *Home* y μ se estiman para la primera jornada y no cambian durante la temporada, pues se presuponen constantes (y así se reduce el tiempo de cómputo), mientras que los parámetros *Ataque* y *Defensa* se van estimando jornada a jornada. Cabe recordar que en este modelo se ha mantenido la función de ponderación temporal (utilizada en el Modelo 2) en la pseudo-verosimilitud, la cual asigna mayor peso a los partidos más recientes, permitiendo que las estimaciones reflejen de forma más precisa el rendimiento actual de los equipos. En la siguiente tabla se muestran los parámetros estimados en la primera jornada para 10 equipos:

Tabla 3.9: Habilidades estimadas Jornada 1 (Modelo 3)

Jornada	Equipo	Ataque	Defensa	β^{home}	β^{away}
1	Betis	-0.024	-0.213	0.647	-3.885
1	Girona	0.212	0.014	0.488	0.327
1	Barcelona	0.286	-0.859	-0.562	1.196
1	Celta	-0.269	-0.187	0.893	1.108
1	Villarreal	0.314	-0.201	0.822	-4.124
1	Eibar	-0.418	0.139	-1.005	-0.390
1	Real Madrid	0.412	-0.345	0.138	0.060
1	Vallecano	-0.064	0.166	-0.292	-4.368
1	Ath Bilbao	-0.112	-0.152	-3.936	0.609
1	Valencia	-0.329	-0.227	0.736	0.894

De forma similar a los dos modelos que preceden, se representa la evolución de la habilidad ofensiva y defensiva estimada a lo largo de las jornadas para cinco equipos seleccionados: Real Madrid, Barcelona, Atlético de Madrid, Betis y Granada.




Figura 3.8: Evolución de la habilidad ofensiva (Modelo 3)




Figura 3.9: Evolución de la habilidad defensiva (Modelo 3)

En este caso, los valores de los parámetros se sitúan en un rango diferente, con una distribución más centrada en torno al cero. Como era de esperar, el Real Madrid evoluciona positivamente a lo largo de la temporada, consolidándose como el mejor equipo tanto ofensiva como defensivamente durante buena parte del campeonato.

A continuación, se muestra el resto de parámetros del modelo:

Parámetro μ : 0.06

Ventaja de jugar en casa (Home): 0.407

Parámetro de covarianza β^{cte} : -3.049

3.4.2. Estrategia de apuestas

Veamos los resultados obtenidos con este modelo basado en la distribución de Poisson bivariada.

Tabla 3.10: Ganancia neta (Modelo 3)

Metrica	Valor
Ganancia neta total	8.98
Numero de apuestas	38
ROI	0.2363

La aplicación de la estrategia de apuestas con las predicciones del Modelo 3 genera una ganancia neta de 8,98 unidades monetarias tras 38 apuestas realizadas. Esto se traduce en un ROI del 23,63 %, el más elevado hasta el momento.

Tabla 3.11: Apuestas ganadas vs falladas (Modelo 3)

Tipo_Apuesta	Fallada	Ganada
Over	2	9
Under	7	20

De las 38 apuestas realizadas, se han acertado 27 y fallado 11, lo que supone un porcentaje de acierto del 71,1 %. Este nivel de acierto es, de nuevo, bastante consistente.

Tabla 3.12: Ganancias por tipo de apuesta (Modelo 3)

Tipo_Apuesta	Apuestas	Ganancia_Total	ROI
Over	11	3.21	0.2918
Under	27	5.77	0.2137




Figura 3.10: Ganancias por tipo de apuesta (Modelo 3)

Tal y como reflejan la tabla y el gráfico anteriores, ambas categorías de apuesta (Over y Under) han generado beneficios, destacando especialmente las apuestas a más de 2,5

goles con un ROI del 29,18 %. No obstante, las apuestas a menos de 2,5 goles, a pesar de tener un ROI algo menor (21,37 %), han sido más frecuentes, contribuyendo en mayor medida a la ganancia total del modelo.

El Modelo 3 ha ofrecido el mejor rendimiento de los tres modelos de Poisson evaluados en términos de ROI. La introducción de un componente de dependencia entre los goles de ambos equipos, aunque supone una mayor complejidad y coste computacional, parece traducirse en resultados más precisos y rentables dentro del contexto de las apuestas deportivas.

Los siguientes modelos están basados en técnicas de aprendizaje automático, los cuales ofrecen un enfoque alternativo para la predicción de resultados futbolísticos.

3.5. Random Forest de regresión

3.5.1. Ajuste y validación del modelo

Este modelo emplea bosques aleatorios de regresión para predecir el número de goles de cada equipo en un partido, utilizando covariables asociadas a los equipos. Dado que las predicciones son valores continuos (habitualmente decimales), se interpretan como los parámetros λ de distribuciones de Poisson independientes ($Po(\lambda)$), lo que permite tener una estimación del número de goles esperado de cada equipo en un encuentro.

En primer lugar, se separan los datos en conjunto de entrenamiento (temporadas 2018/2019 a 2021/2022) y test (temporada 2022/2023), y se ajusta un random forest optimizando el parámetro *mtry* mediante validación cruzada, obteniéndose la siguiente salida:

Tabla 3.13: Resultados validación cruzada (Modelo 4)

mtry	RMSE	Rsquared	MAE	RMSESD	RsquaredSD	MAESD
2	1.1829	0.0359	0.9326	0.0285	0.0106	0.0250
5	1.1834	0.0368	0.9347	0.0315	0.0121	0.0280
3	1.1839	0.0361	0.9340	0.0302	0.0107	0.0277
4	1.1842	0.0359	0.9348	0.0310	0.0119	0.0270
6	1.1850	0.0361	0.9350	0.0328	0.0121	0.0294

Se observa que el valor óptimo del parámetro *mtry* es 2, pues es el que minimiza el error cuadrático medio (RMSE). Se ajusta entonces el modelo de random forest utilizando dicho valor y un total de 1000 árboles. Además, la importancia de las covariables empleadas en el modelo se muestra en el siguiente gráfico:




Figura 3.11: Importancia de las covariables (Modelo 4)

Se evalúa ahora el rendimiento del modelo en el conjunto test (temporada 2022/2023), mediante el Error Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE) cometidos en la predicción de los goles de cada partido:

RMSE: 1.104

MAE: 0.864

Aplicamos ahora el modelo ajustado a los partidos de la temporada 2023/2024. Se utilizan los valores continuos predichos por el Random Forest como medias de distribuciones de Poisson independientes, a partir de las cuales se generan valores enteros para los goles de cada uno de los dos equipos en cada partido.

Como ejemplo, en la siguiente tabla se muestran las primeras predicciones generadas:

Tabla 3.14: Primeras predicciones generadas (Modelo 4)

PartidoID	Equipo	Rival	Goles	GolesPredichos
1	Almeria	Vallecano	0	1.22
1	Vallecano	Almeria	2	1.47
2	Sevilla	Valencia	1	1.13
2	Valencia	Sevilla	2	1.12
3	Sociedad	Girona	1	1.31
3	Girona	Sociedad	1	0.70

En este caso, se emplean las predicciones generadas por el modelo de Random Forest para estimar el número esperado de goles de cada equipo en los partidos de la temporada 2023/2024. Estas predicciones, contenidas en la columna **GolesPredichos**, se interpretan como las medias de distribuciones de Poisson independientes. A partir de dichas medias, se calcula la probabilidad de que el total de goles en cada partido sea mayor o menor a 2,5, lo que permite aplicar la estrategia de apuestas descrita anteriormente en el mercado *Over/Under*.

3.5.2. Estrategia de apuestas

A continuación, se presentan los resultados obtenidos al aplicar la estrategia de apuestas al mercado *Over/Under 2.5 goles*, utilizando las predicciones del modelo Random Forest como base.

Tabla 3.15: Ganancia neta (Modelo 4)

Metrica	Valor
Ganancia neta total	2.15
Numero de apuestas	19
ROI	0.1132

El modelo genera una ganancia neta de 2,15 unidades monetarias tras 19 apuestas realizadas, lo que equivale a un ROI del 11,3%. A pesar de ser una cantidad más modesta que la obtenida con algunos modelos anteriores, se sigue obteniendo una rentabilidad económica positiva.

Tabla 3.16: Apuestas ganadas vs falladas (Modelo 4)

Tipo_Apuesta	Fallada	Ganada
Over	2	2
Under	5	10

Del total de 19 apuestas realizadas, se observa que 12 han sido acertadas, lo que representa un porcentaje de acierto del 63,2%.

Tabla 3.17: Ganancias por tipo de apuesta (Modelo 4)

Tipo_Apuesta	Apuestas	Ganancia_Total	ROI
Under	15	2.06	0.1373
Over	4	0.09	0.0225




Figura 3.12: Ganancias por tipo de apuesta (Modelo 4)

El mayor número de apuestas se concentra en el mercado *Under*, con 15 apuestas realizadas, frente a solo 4 en *Over*. Ambas estrategias arrojan ganancias positivas, aunque el rendimiento económico de las apuestas a menos de 2,5 goles destaca claramente con un ROI de 13,73 % frente al 2,25 % de las apuestas a más de 2,5 goles.

En definitiva, el Modelo 4 logra obtener un ROI positivo al aplicar la estrategia de apuestas basada en el número de goles, aunque con unos beneficios algo más reducidos. Esto sugiere que los modelos clásicos basados en Poisson podrían resultar más efectivos para la predicción del número de anotaciones.

A partir de este punto, los modelos 5 y 6 emplean algoritmos de clasificación y se orientan a la predicción directa del resultado del partido en formato 1X2.

3.6. Random Forest de clasificación

3.6.1. Ajuste y validación del modelo

En este apartado se aplica un modelo basado en Random Forest de clasificación con el fin de predecir el resultado de los partidos (victoria local, empate o victoria visitante). A diferencia de los modelos anteriores centrados en el número de goles, aquí la variable respuesta es categórica. Se utilizan los mismos datos y covariables del modelo de regresión. El modelo se entrenará y ajustará mediante validación cruzada, y su objetivo principal es desarrollar una estrategia de apuestas rentable basada en la predicción del resultado final.

Al igual que en el modelo justamente anterior, se divide el conjunto de datos en entrenamiento (temporadas 2018/2019 a 2021/2022) y test (temporada 2022/2023). Antes de proceder con la construcción del modelo, se analiza la distribución de las observaciones entre las 3 clases del conjunto de entrenamiento para detectar si los datos están desbalanceados. La tabla resultante es la siguiente:

Tabla 3.18: Frecuencia de clases (conjunto train)

Clase	Frecuencia
Empate	435
Victoria Local	665
Victoria Visitante	420

Como puede observarse, las victorias locales son considerablemente más frecuentes que los empates o las victorias visitantes, lo cual podría inducir un sesgo en el modelo hacia la clase “Victoria Local”. Para evitar esto, se realizará un proceso de balanceo (upsampling) sobre el conjunto de entrenamiento, asegurando una representación equitativa de cada clase. El resultado de la nueva distribución es el siguiente:

Tabla 3.19: Frecuencia de clases tras balanceo

Clase	Frecuencia
Empate	665
Victoria Local	665
Victoria Visitante	665

Para validar el modelo y seleccionar el valor óptimo del hiperparámetro $mtry$, se empleará validación cruzada con 5 pliegues y 5 repeticiones. Se evaluará el rendimiento del modelo mediante métricas como la precisión global y la precisión específica para cada clase (Victoria Local, Empate y Victoria Visitante).

Dado que el objetivo final es desarrollar una estrategia de apuestas lo más rentable posible, elegiremos el valor de $mtry$ que genere tanto mayor precisión global como mayor precisión en las clases “Empate” y “Victoria Visitante”, puesto que ambas clases suelen estar asociadas a cuotas más altas en las casas de apuestas. Se genera la siguiente salida en R:

Tabla 3.20: Mejores modelos validación cruzada (Modelo 5)

$mtry$	Accuracy	Precision_Local	Precision_Empate	Precision_Visitante	PrecMedia_Emp_Visit
3	0.6683	0.5919	0.6680	0.7450	0.7065
2	0.6656	0.5901	0.6583	0.7483	0.7033
4	0.6642	0.5889	0.6620	0.7417	0.7018
6	0.6634	0.5847	0.6629	0.7426	0.7027
5	0.6587	0.5780	0.6592	0.7389	0.6991

Se detecta que el mejor resultado se obtiene con un valor de $mtry = 3$, alcanzando una precisión global de 66,82%. Además, es el valor que logra mejor sensibilidad en las clases “Empate” y “Victoria Visitante”, lo cual es especialmente relevante teniendo en cuenta el objetivo teniendo en cuenta el objetivo del modelo: obtener la mayor rentabilidad posible mediante la estrategia de apuestas ya explicada. Es por ello que se usará este valor del parámetro $mtry$ para desarrollar el modelo y realizar las predicciones.

Para evaluar la capacidad de generalización del modelo, se utiliza el conjunto test correspondiente a la temporada 2022/2023. Se entrenan 50 modelos independientes de Random Forest con los hiperparámetros seleccionados anteriormente (en particular, $mtry = 3$ y $ntree = 500$). Para cada modelo se realizan predicciones sobre el conjunto de test y se calculan tanto la precisión global como la precisión por clase. El objetivo es obtener una estimación robusta del rendimiento medio del modelo en datos no vistos.

Tabla 3.21: Precisión media conjunto test (Modelo 5)

Clase	Precisión.Media
Empate	0.236
Victoria Local	0.678
Victoria Visitante	0.487
Global	0.520

Se tiene una precisión global media del 52 % sobre el conjunto test, es decir, predice correctamente el resultado de más de la mitad de los partidos. Puede considerarse que el modelo funciona de forma adecuada, pues predecir más de la mitad de los resultados de los partidos de toda una temporada, a priori, parece una cuestión complicada, teniendo en cuenta la alta aleatoriedad e incertidumbre inherente al fútbol. Aunque la precisión no es perfecta, el modelo demuestra una capacidad predictiva destacable en un problema tan complejo.

Por otro lado, se observa una mayor precisión en la clase “Victoria Local” (67,8 %), mientras que las clases “Empate” (23,6 %) y “Victoria Visitante” (48,7 %) presentan valores más bajos, lo que refleja la gran dificultad de predecir, en particular, los empates.

3.6.2. Estrategia de apuestas

Tras evaluar el rendimiento del modelo de clasificación con los datos test, se plantea ahora un análisis para determinar si las predicciones pueden aprovecharse para generar beneficios económicos a través de apuestas deportivas en la temporada 2023/2024.

Para ello, se simula una estrategia en la que se apuesta 1 unidad monetaria al resultado predicho por el modelo para cada partido de la temporada 2023/2024, utilizando las cuotas reales ofrecidas por la casa de apuestas BET365. Dado que el modelo presenta cierta aleatoriedad en cada ejecución, se repite el proceso 100 veces, entrenando modelos distintos bajo las mismas condiciones y registrando la ganancia neta obtenida en cada caso. Esto permite calcular tanto la ganancia neta media como el retorno medio de la inversión (ROI), proporcionando una visión más robusta sobre la rentabilidad potencial sobre la nueva temporada.

Se comienza presentando la precisión sobre la temporada 2023/2024:

Tabla 3.22: Precisión media 2023/2024 (Modelo 5)

Clase	Precisión
Empate	0.333
Victoria Local	0.652
Victoria Visitante	0.379
Global	0.486

Por su parte, el rendimiento económico obtenido tras aplicar los 100 modelos entrenados a la estrategia de apuestas explicada viene dado por los siguientes resultados:

Ganancia neta media: 20.22

Retorno medio de la inversión (ROI): 5.32 %

La ganancia neta media esperada, calculada a partir de los 100 modelos desarrollados, es de 20.22€. Por tanto, hemos desarrollado un modelo que, en promedio, genera un retorno económico positivo. El retorno medio esperado (ROI) sobre el dinero total apostado es del 5,32 %.

Se abren ahora dos vías de estrategias de apuesta distintas:

La primera de ellas consiste en utilizar los 100 modelos entrenados, es decir, para cada partido tenemos 100 predicciones divididas entre los 3 posibles resultados. Entonces, para ser continuista con el enfoque de apostar una unidad monetaria (1€) a cada partido, el plan se basaría en apostar en céntimos a cada resultado el porcentaje de modelos que lo predicen, esto es, si para un partido determinado se tiene que el 70 % de los modelos predice Victoria Local, el 20 % Empate y el 10 % Victoria Visitante, pues se apostarían 0.70€ a Victoria Local, 0.20€ a Empate y 0.10€ a Victoria Visitante. Con este enfoque se cumple que la ganancia neta esperada es igual a la media de las ganancias individuales (calculada anteriormente). Más adelante veremos que esta estrategia es más conservadora porque se espera una ganancia positiva, y el intervalo de confianza es poco amplio y no contiene valores negativos.

La segunda estrategia se basa en entrenar en condiciones similares un solo modelo nuevo y apostar 1€ al resultado de cada partido según su predicción. A continuación, se demostrará que esta estrategia es más arriesgada que la anterior, pero también puede generar mayores beneficios, puesto que el intervalo de confianza de la ganancia neta esperada es mucho más amplio por ambos lados.

Ahora calcularemos intervalos de confianza al 95 % para la media de las ganancias obtenidas al utilizar los 100 modelos, así como para la ganancia puntual al seleccionar un único modelo de forma aleatoria. Primero veamos si la variable ganancias sigue una distribución normal mediante gráficos y el test de Shapiro-Wilk.




Figura 3.13: Gráficos de normalidad para las ganancias (Modelo 5)

Como el valor-p del test de Shapiro-Wilk es $0.9171 > 0.05$, no podemos rechazar la hipótesis nula de normalidad. Por tanto, asumimos que las ganancias siguen una distribución normal.

Como además se desconoce la varianza poblacional, los intervalos de confianza al 95 % para la media de las ganancias (usando 100 modelos) y para un único modelo nuevo (aleatorio) se calculan utilizando la distribución t de Student. El IC al 95 % para la media poblacional μ (ganancia media al usar 100 modelos) es:

$$\bar{x} \pm t_{\alpha/2, n-1} \cdot \left(\frac{s}{\sqrt{n}} \right) \quad \text{donde:}$$

- $\bar{x}$ es la media muestral.
- s es la desviación estándar muestral.
- n es el tamaño de la muestra (100 en este caso).
- $t_{\alpha/2, n-1}$ es el valor crítico de la t de Student con $n - 1$ grados de libertad.

Se obtiene el siguiente resultado:

Tabla 3.23: IC al 95 % para las ganancias - Estrategia conservadora (Modelo 5)

Metrica	LimiteInferior	LimiteSuperior
Ganancia neta media	18.34 €	22.1 €
ROI	4.83 %	5.82 %

Como se puede observar, la ganancia neta esperada se sitúa en un rango positivo, lo que sugiere que esta estrategia de apuestas, en media, es rentable; además de conservadora, pues el intervalo de confianza es relativamente estrecho.

El IC para la ganancia neta esperada de un nuevo modelo aleatorio entrenado bajo las mismas condiciones es:

$$\bar{x} \pm t_{\alpha/2, n-1} \cdot \left(s \cdot \sqrt{1 + \frac{1}{n}} \right)$$

Tabla 3.24: IC al 95 % para las ganancias - Estrategia arriesgada (Modelo 5)

Metrica	LimiteInferior	LimiteSuperior
Ganancia neta esperada	1.3 €	39.14 €
ROI	0.34 %	10.3 %

La variabilidad es considerablemente mayor que en la estrategia conservadora, pues los intervalos de confianza son mucho más amplios. Esta estrategia es más arriesgada, pero también puede generar mayores beneficios.

Ahora realizaremos un análisis de las ganancias obtenidas por cada tipo de apuesta: ‘Victoria Local’, ‘Empate’ y ‘Victoria Visitante’.

Tabla 3.25: Ganancias por tipo de apuesta (Modelo 5)

Resultado_Predicho	Apuestas_Medias	Ganancia_Media	ROI_Medio
Empate	110.74	14.10	0.13
Victoria Visitante	79.64	7.61	0.10
Victoria Local	189.62	-1.50	-0.01




Figura 3.14: Ganancias por tipo de apuesta (Modelo 5)

Se percibe que las apuestas a empates o victorias visitante son consistentes, pues generan retornos económicos del 13 % y 10 %, respectivamente. Por otra parte, las apuestas a victorias locales generan una mínima pérdida (1 %) a lo largo de la temporada.

Hacemos ahora un análisis por rangos de cuotas, los cuales son los siguientes:

- Bajas: Cuotas entre 1.00 y 1.50

- Medias: Cuotas entre 1.51 y 2.00
- Altas: Cuotas entre 2.01 y 3.00
- Muy Altas: Cuotas superiores a 3.00

Tabla 3.26: Ganancias por rango de cuotas (Modelo 5)

Rango_Cuota	Apuestas_Medias	Ganancia_Media	ROI_Medio
Bajas	49.83	5.77	0.12
Muy Altas	133.73	12.42	0.09
Medias	101.77	3.43	0.03
Altas	94.67	-1.40	-0.01




Figura 3.15: Ganancias por rango de cuotas (Modelo 5)

En este caso, las únicas cuotas que parecen rentables económicamente a largo plazo son las cuotas bajas y las muy altas, originando retornos del 12 % y 9 %, correspondientemente. Las cuotas medias y altas no son muy beneficiosas en términos económicos.

A continuación, analizamos el desempeño de cada equipo por separado, según jueguen como local o como visitante. Cabe destacar que cada equipo juega 19 partidos como local y otros 19 como visitante a lo largo del campeonato.




Figura 3.16: Ganancias por equipo local (Modelo 5)

Cuando juegan como local, los equipos que generan un mayor retorno económico son el Cádiz, el Real Madrid y el Betis, obteniéndose una ganancia neta que supera el 30 % del dinero total apostado en los 19 partidos que cada uno disputó en casa. Estas son cifras bastante positivas. En cuanto a los equipos que originan pérdidas, los más considerables son Sevilla, Villarreal y Athletic de Bilbao, con cantidades algo mayores del 20 %.




Figura 3.17: Ganancias por equipo visitante (Modelo 5)

Por otro lado, cuando juegan a domicilio, la Real Sociedad genera un retorno económico de aproximadamente el 75 %, una cantidad realmente alta. Seguidamente aparecen Sevilla y Granada, con retornos alrededor del 55 % y 50 %, respectivamente. Son cifras inferiores a la de la Real Sociedad, pero siguen siendo muy altas y relevantes. En el extremo contrario se encuentra el Betis, el cual provoca pérdidas de algo menos del 50 % sobre el total invertido.

3.7. XGBoost de clasificación

3.7.1. Ajuste y validación del modelo

En este apartado se aplica un modelo basado en XGBoost para la clasificación del resultado de los partidos de fútbol (victoria local, empate o victoria visitante). Al igual que en el modelo de Random Forest, la variable respuesta es categórica y se emplean las mismas covariables y conjunto de datos. El modelo será entrenado y ajustado mediante validación cruzada para optimizar sus parámetros. El objetivo, al igual que antes, es construir una estrategia de apuestas que maximice la rentabilidad a partir de las predicciones del resultado final.

Dividimos los datos en entrenamiento (18/19 - 21/22) y test (22/23) de forma idéntica al modelo previo. Como el conjunto de entrenamiento está desbalanceado porque hay bastantes más observaciones de victorias locales que de empates y victorias visitantes, asignamos pesos a las clases para compensar este desequilibrio, penalizando así en mayor medida los errores en las clases minoritarias.

Para ajustar el modelo XGBoost, se realizará una validación cruzada de 5 pliegues. El objetivo de este procedimiento es seleccionar la mejor combinación de hiperparámetros para el modelo. Algunos hiperparámetros del modelo se mantienen fijos durante el proceso:

- *gamma* = 1
- *colsample_bytree* = 0,8
- *min_child_weight* = 1
- *subsample* = 0,8

Se probarán distintas combinaciones con el resto de hiperparámetros, generando una rejilla (grid) de búsqueda aleatoria:

- *nrounds*: número de iteraciones (valores considerados: 100, 200, 300, 400)
- *max_depth*: profundidad máxima de los árboles (3, 5, 7, 9)
- *eta*: tasa de aprendizaje (0.05, 0.075, 0.10, 0.15)

De todas las combinaciones posibles, se selecciona aleatoriamente un subconjunto de 40 configuraciones para reducir el coste computacional.

El criterio principal para seleccionar la mejor combinación de hiperparámetros es la maximización de la precisión media en las clases minoritarias: “Empate” y “Victoria Visitante”, aunque también se tendrá en cuenta la precisión global para no comprometer el rendimiento general del modelo.

Tabla 3.27: Mejores modelos validación cruzada (Modelo 6)

eta	max_depth	nrounds	Prec_Global	PrecMedia_Emp_Visit	Prec_Loc	Prec_Emp	Prec_Visit
0.075	9	100	0.4711	0.4224	0.5353	0.3471	0.4976
0.075	9	300	0.4711	0.4188	0.5398	0.3494	0.4881
0.150	5	100	0.4704	0.4144	0.5444	0.3241	0.5048
0.150	5	200	0.4691	0.4142	0.5414	0.3356	0.4929
0.075	3	300	0.4730	0.4133	0.5519	0.3218	0.5048
0.100	3	100	0.4757	0.4055	0.5684	0.2920	0.5190
0.075	3	200	0.4730	0.4041	0.5639	0.3034	0.5048
0.050	3	100	0.4737	0.3905	0.5835	0.2667	0.5143

Se detecta que la combinación de hiperparámetros $eta = 0.075$, $max_depth = 9$ y $nrounds = 100$ es la que proporciona la mayor precisión media en las clases minoritarias (“Empate” y “Victoria Visitante”), con un valor de 0,4224. Además, su precisión global (0,4711) se encuentra muy próxima al máximo observado, lo que la convierte en una opción equilibrada y robusta. Por tanto, seleccionamos esta combinación como la óptima para el modelo, al priorizar un buen rendimiento en las clases minoritarias sin sacrificar la precisión total del modelo.

Siguiendo la línea del Random Forest, para evaluar la generalización del modelo sobre datos no vistos, se generan 50 modelos aleatorios independientes con los hiperparámetros seleccionados sobre el conjunto test. Se obtienen los siguientes resultados:

Tabla 3.28: Precisión media conjunto test (Modelo 6)

Clase	Precisión.Media
Empate	0.222
Victoria Local	0.595
Victoria Visitante	0.531
Global	0.489

En comparación con el Random Forest, el modelo basado en XGBoost presenta una ligera disminución en la precisión global (0,489 frente a 0,52). Sin embargo, logra una mejor precisión en la clase “Victoria Visitante” (0,531 frente a 0,487), lo cual es especialmente relevante teniendo en cuenta que esta clase suele tener las cuotas de apuestas más altas. Por el contrario, la precisión en la clase “Victoria Local” disminuye levemente, y la clase “Empate” se mantiene con una precisión similar. En resumen, aunque el rendimiento global es algo inferior, XGBoost puede ser preferible para obtener mejores resultados económicos, pues parece que acierta con mayor precisión las victorias a domicilio, las cuales suelen ofrecer las mayores cuotas en el mercado de apuestas.

3.7.2. Estrategia de apuestas

Seguidamente, se aplica el mismo procedimiento que en el modelo previo sobre la temporada 2023/2024. Las precisiones global y por clases sobre esta nueva temporada vienen dadas por:

Tabla 3.29: Precisión media 2023/2024 (Modelo 6)

Clase	Precisión
Empate	0.353
Victoria Local	0.655
Victoria Visitante	0.457
Global	0.515

Por su parte, la ganancia obtenida aplicando 100 modelos es la siguiente:

Ganancia neta media XGB: 34.7437

ROI medio: 9.143079 %

La ganancia neta media esperada a partir de los 100 modelos desarrollados es de 34,74€. Por tanto, hemos desarrollado un modelo que, en media, obtiene un retorno económico positivo, que mejora razonablemente al Random Forest. El retorno medio esperado (ROI) es del 9,14 % sobre el dinero total apostado.

Al igual que antes, se abren dos vías de estrategias de apuesta distintas:

La primera de ellas consiste en utilizar los 100 modelos entrenados, es decir, para cada partido tenemos 100 predicciones divididas entre los 3 posibles resultados. Entonces, para ser continuista con el enfoque de apostar una unidad monetaria (1€) a cada partido, el plan se basaría en apostar en céntimos a cada resultado el porcentaje de modelos que lo predicen, esto es, si para un partido determinado se tiene que el 70 % de los modelos predice Victoria Local, el 20 % Empate y el 10 % Victoria Visitante, pues se apostarían 0.70€ a Victoria Local, 0.20€ a Empate y 0.10€ a Victoria Visitante. Con este enfoque se cumple que la ganancia neta esperada es igual a la media de las ganancias individuales (calculada anteriormente). Más tarde veremos que esta estrategia es más conservadora porque se espera una ganancia positiva, y el intervalo de confianza es poco amplio y no contiene valores negativos.

La segunda estrategia se basa en entrenar en condiciones similares un solo modelo nuevo y apostar 1€ al resultado de cada partido según su predicción. A continuación, se demostrará que esta estrategia es más arriesgada que la anterior, pero también puede generar mayores beneficios, puesto que el intervalo de confianza de la ganancia neta esperada es mucho más amplio por ambos lados.

Ahora calcularemos intervalos de confianza al 95 % para la media de las ganancias obtenidas al utilizar los 100 modelos, así como para la ganancia puntual al seleccionar un único modelo de forma aleatoria. Primero veamos si la variable ganancias sigue una distribución normal mediante gráficos y el test de Shapiro-Wilk.




Figura 3.18: Gráficos de normalidad para las ganancias (XGB)

Como el valor-p del test de Shapiro-Wilk es $0.5957 > 0.05$, no podemos rechazar la hipótesis nula de normalidad. Por tanto, asumimos que las ganancias siguen una distribución normal.

Como además se desconoce la varianza poblacional, los intervalos de confianza al 95 % para la media de las ganancias (usando 100 modelos) y para un único modelo nuevo (aleatorio) se calculan utilizando la distribución t de Student. El IC al 95 % para la media poblacional μ (ganancia media al usar 100 modelos) es:

$$\bar{x} \pm t_{\alpha/2, n-1} \cdot \left(\frac{s}{\sqrt{n}} \right)$$

Se obtienen entonces los siguientes intervalos de confianza:

Tabla 3.30: IC al 95 % para las ganancias - Estrategia conservadora (Modelo 6)

Metrica	LimiteInferior	LimiteSuperior
Ganancia neta media	32.51 €	36.98 €
ROI	8.56 %	9.73 %

Estos resultados representan una mejora notable respecto al modelo anterior. El intervalo de confianza para el retorno económico es bastante estrecho, lo que indica una alta consistencia en las ganancias esperadas. Además, al situarse cercano al 10 %, este retorno se considera muy atractivo para una estrategia de apuestas, reflejando un buen equilibrio entre rentabilidad y estabilidad.

El IC para la ganancia neta esperada de un nuevo modelo aleatorio entrenado bajo las mismas condiciones es:

$$\bar{x} \pm t_{\alpha/2, n-1} \cdot \left(s \cdot \sqrt{1 + \frac{1}{n}} \right)$$

Tabla 3.31: IC al 95 % para las ganancias - Estrategia arriesgada (Modelo 6)

Metrica	LimiteInferior	LimiteSuperior
Ganancia neta esperada	12.31 €	57.18 €
ROI	3.24 %	15.05 %

Estos amplios intervalos reflejan que la estrategia basada en un solo modelo presenta mayor volatilidad e inestabilidad. Por tanto, puede producir resultados tanto modestos como muy exitosos. Sin embargo, incluso el límite inferior del intervalo indica una ganancia económica notable.

Al igual que anteriormente, se realiza un estudio de las ganancias por tipo de apuesta, rango de cuota y equipo, respectivamente.

El análisis por cada tipo de apuesta ('Victoria Local', 'Empate', 'Victoria Visitante') devuelve los siguientes resultados:

Tabla 3.32: Ganancias por tipo de apuesta (Modelo 6)

Resultado_Predicho	Apuestas_Medias	Ganancia_Media	ROI_Medio
Empate	108.79	17.75	0.16
Victoria Visitante	96.22	12.02	0.12
Victoria Local	174.99	4.98	0.03




Figura 3.19: Ganancias por tipo de apuesta (Modelo 6)

Con este modelo, los tres tipos de apuesta considerados generan beneficios, situándose las apuestas a empates en primer lugar con un retorno económico neto del 16 % sobre el total apostado.

Hacemos ahora un análisis por rangos de cuotas, los cuales son los siguientes:

- Bajas: Cuotas entre 1.00 y 1.50
- Medias: Cuotas entre 1.51 y 2.00
- Altas: Cuotas entre 2.01 y 3.00
- Muy Altas: Cuotas superiores a 3.00

Tabla 3.33: Ganancias por rango de cuotas (Modelo 6)

Rango_Cuota	Apuestas_Medias	Ganancia_Media	ROI_Medio
Muy Altas	124.04	19.39	0.16
Bajas	54.80	4.71	0.09
Altas	91.60	7.29	0.08
Medias	109.56	3.36	0.03




Figura 3.20: Ganancias por rango de cuotas (Modelo 6)

Se cumple también que todos los rangos de apuesta producen beneficios. Se sitúa a la cabeza las apuestas a cuotas muy altas (mayores a 3€), desencadenando un retorno neto medio del 16%. Es por ello que las apuestas a este tipo de cuotas pueden considerarse una gran oportunidad de mercado.

A continuación, analizamos el desempeño de cada equipo por separado, según jueguen como local o como visitante. Cabe destacar que cada equipo juega 19 partidos como local y otros 19 como visitante a lo largo del campeonato.




Figura 3.21: Ganancias por equipo local (Modelo 6)

Cuando juegan como local, los equipos que generan un mayor retorno económico son el Celta, el Cádiz y el Almería, obteniéndose una ganancia neta que supera el 40 % del dinero total apostado en los 19 partidos que cada uno disputó en casa. Son cifras bastante altas, que mejoran el rendimiento del modelo anterior en lo que se refiere a los equipos en los que se obtienen mayores ganancias. Además, Real Madrid y Atlético de Madrid los siguen con ganancias considerables que rondan el 30 %. En el lado negativo se encuentran Sevilla y Girona, los cuales provocan pérdidas de algo mas del 20 %.




Figura 3.22: Ganancias por equipo visitante (Modelo 6)

Por otro lado, cuando juegan a domicilio, el Sevilla genera un retorno económico de aproximadamente el 50 %, una cantidad realmente alta, pero no tanto como la Real Sociedad en el Random Forest. Seguidamente aparecen Mallorca y Real Sociedad, con retornos cerca del 40 %. Los peores equipos en cuanto a términos económicos son Villarreal, Celta y Getafe, creando pérdidas alrededor del 20 %.

Capítulo 4

Comparación de resultados y conclusiones

4.1. Comparación del rendimiento de los modelos

A raíz de los resultados obtenidos en todos los modelos desarrollados, se realiza una comparación con el objetivo de evaluar su rendimiento y utilidad.

Por un lado, se analizan los modelos orientados a la predicción del número de goles (Modelos 1, 2, 3 y 4), a través del rendimiento obtenido en la estrategia de apuestas basada en el mercado de goles totales (Over/Under 2.5). La métrica principal utilizada es el retorno sobre la inversión (ROI), tanto global como desglosado por tipo de apuesta (Over o Under), lo que permite comparar de forma relativa la eficacia de cada modelo.

Por otro lado, se comparan los modelos de clasificación (Modelos 5 y 6) que predicen directamente el resultado del partido en formato 1X2. En este caso, la evaluación incluye métricas clásicas de precisión (tanto global como por clase) y el ROI obtenido al aplicar la estrategia de apuestas correspondiente.

4.1.1. Modelos orientados a la predicción de goles

A continuación, se comparan los resultados obtenidos por los cuatro modelos de regresión al aplicar la estrategia de apuestas basada en el mercado Over/Under 2,5 goles.

Tabla 4.1: Comparación de modelos de regresión (mercado Over/Under 2.5 goles)

Modelo	Apuestas realizadas	Ganancia neta (u.m.)	ROI
M1: PI	37	3,85	10,41 %
M2: PI+PT	71	13,56	19,10 %
M3: PB	38	8,98	23,63 %
M4: RF	19	2,15	11,32 %

Como se aprecia en la tabla, el modelo M3: PB (Poisson Bivariado con ponderación temporal) es el que alcanza el mayor retorno económico, con un ROI del 23,63 %, una cifra considerablemente alta dada la dificultad existente de obtener beneficios sostenidos en el ámbito de las apuestas deportivas. Le sigue el modelo 2 (Poisson con independencia y ponderación temporal), con un ROI del 19,10 %. Los modelos 1 (Poisson con independencia) y 4 (Random Forest) presentan los peores resultados, con retornos más modestos y muy similares entre sí. Esto refleja que el modelo de Poisson más simple resulta menos efectivo que variantes más complejas, y que el modelo de aprendizaje automático Random Forest no supera el rendimiento de las técnicas clásicas de Poisson. En conjunto, estos resultados sugieren que incorporar dependencia entre los goles y emplear ponderación temporal en las estimaciones puede mejorar notablemente la capacidad predictiva de los modelos.

Cabe destacar que, pese a las diferencias en el rendimiento, todos los modelos de regresión analizados logran generar ganancias netas positivas, lo que refuerza la viabilidad de su aplicación en la estrategia de apuestas desarrollada.

Ahora, con el objetivo de analizar si resulta más rentable realizar un tipo de apuesta u otro (Over/Under 2,5 goles), en la siguiente tabla se muestran los ROI obtenidos por cada tipo de apuesta en los diferentes modelos de regresión.

Tabla 4.2: ROI por tipo de apuesta y modelo (Regresión)

Modelo	ROI Over	ROI Under
M1: PI	32,50 %	9,14 %
M2: PI + PT	27,95 %	15,12 %
M3: PB	29,18 %	21,37 %
M4: RF	2,25 %	13,73 %

En general, los resultados reflejan que las apuestas a más de 2,5 goles ofrecen un mayor retorno económico que las apuestas a menos de 2,5 goles en la mayoría de los modelos considerados.

4.1.2. Modelos orientados a la predicción del resultado

En este apartado se comparan los modelos de clasificación (modelos 5 y 6). En primer lugar se hace la comparación en términos de precisión global y precisión por clases, utilizando las predicciones realizadas sobre la temporada 2023/2024. El objetivo es evaluar su capacidad para anticipar correctamente el signo del resultado de los partidos (1X2).

Tabla 4.3: Comparación de precisión por clases (temporada 2023/2024)

Modelo	Precisión global	Precisión VL	Precisión E	Precisión VV
M5: RF	0,486	0,652	0,333	0,379
M6: XGB	0,515	0,655	0,353	0,457

Se observa que el modelo XGBoost supera al modelo de bosques aleatorios en todas las métricas de precisión, tanto a nivel global como por clases. En particular, la diferencia

más significativa se observa en en la predicción de victorias visitantes, donde alcanza una mejora notable. Esto es especialmente relevante dado que este tipo de resultados suelen ser más difíciles de predecir correctamente, por lo que suelen tener cuotas de apuesta más altas.

A continuación, se analizan los retornos económicos obtenidos al aplicar la estrategia de apuestas descrita con los modelos de clasificación. Se comparan tanto el ROI medio global como el ROI medio por tipo de apuesta (victoria local, empate y victoria visitante).

Tabla 4.4: ROI por clase y modelo (Clasificación)

Modelo	ROI global	ROI VL	ROI E	ROI VV
M5: RF	5,32 %	-0,79 %	12,73 %	9,55 %
M6: XGB	9,14 %	2,85 %	16,32 %	12,49 %

Como era previsible tras los resultados de precisión mostrados anteriormente, el modelo XGBoost no solo supera al Random Forest en términos de acierto, sino que también obtiene un mayor ROI medio, tanto a nivel global como en cada una de las clases de apuesta. Además, se observa claramente que las apuestas a empates o, incluso, a victorias visitantes resultan mucho más rentables que las apuestas a victorias locales, lo cual es coherente con el hecho de que estas últimas suelen estar asociadas a cuotas de apuesta más bajas.

También se ha llevado a cabo una comparación detallada según el rango de cuota asociado a cada apuesta. Recordemos los cuatro grupos definidos anteriormente: bajas (1.00–1.50), medias (1.51–2.00), altas (2.01–3.00) y muy altas (superiores a 3.00). Esta clasificación permite observar cómo varía la rentabilidad en función del tipo de cuota, y valorar qué rangos resultan más interesantes desde el punto de vista práctico.

Tabla 4.5: ROI por rango de cuota y modelo (Clasificación)

Modelo	1,00-1,50	1,51-2,00	2,01-3,00	>3,00
M5: RF	11,58 %	3,37 %	-1,48 %	9,29 %
M6: XGB	8,59 %	3,07 %	7,96 %	15,63 %

Los resultados muestran que las cuotas bajas (1.00–1.50) y las cuotas muy altas (>3.00) son, en general, las más rentables. El modelo XGBoost resulta más rentable que el Random Forest en todos los rangos, excepto en las cuotas bajas, donde RF obtiene un retorno ligeramente superior. Además, XGBoost tiene un mejor rendimiento cuando se apuesta a eventos con mayor incertidumbre (cuotas mayores a 2,00), lo que podría ser relevante a la hora de diseñar estrategias más rentables, aunque también más arriesgadas.

En conjunto, los resultados obtenidos permiten concluir que el modelo XGBoost no solo presenta una mayor capacidad predictiva, sino que también ofrece un rendimiento económico superior en la mayoría de los escenarios analizados. Su comportamiento más favorable en términos de ROI lo convierte en una alternativa más eficaz que el modelo

basado en Random Forest a la hora de maximizar beneficios potenciales en el contexto de apuestas deportivas.

4.2. Conclusiones

En este trabajo se han explorado diferentes enfoques para predecir resultados futbolísticos y evaluar su rentabilidad mediante el desarrollo de estrategias de apuestas. Entre las técnicas de predicción de goles, el Modelo 3 (Poisson Bivariado con ponderación temporal), ha sido el más eficaz en cuanto al retorno económico. En la categoría de clasificación, el modelo XGBoost ha superado al Random Forest tanto en precisión como en rentabilidad, situándose como la mejor opción entre los dos modelos evaluados en esta familia.

A pesar de los resultados positivos obtenidos, el estudio presenta varias limitaciones. En el caso de los modelos de machine learning, existe margen de mejora en las variables explicativas utilizadas, pues la inclusión de nuevas covariables más relevantes seguramente pueda mejorar el rendimiento. Además, la estrategia de apuestas asociada a los modelos de clasificación no ha tenido en cuenta las probabilidades implícitas ofrecidas por la casa de apuestas, a diferencia de lo que sí se ha hecho en los modelos de goles, lo cual impide detectar con claridad apuestas de valor esperado positivo. Asimismo, otra limitación del estudio es que para la implementación de las estrategias de apuestas solo se han tenido en cuenta las cuotas de la casa de apuestas Bet365. Aunque estas sean representativas, incorporar información de múltiples plataformas de apuestas permitiría identificar mejores oportunidades de valor.

Por último, una posible línea de mejora futura sería aplicar los modelos desarrollados a nuevas temporadas para comprobar si su rendimiento y capacidad para generar beneficios se mantiene en el tiempo, y así validar la robustez y utilidad práctica de estas estrategias en contextos reales.

Bibliografía

- ClubElo (2025). Clubelo - football club elo ratings. <http://clubelo.com/>.
- Dixon, M. J. and Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 46(2):265–280.
- Football-Data.co.uk (2025). Resultados históricos de la primera división española de fútbol. <https://www.football-data.co.uk/spainm.php>.
- Groll, A., Ley, C., Schauburger, G., and Eetvelde, H. V. (2018). Prediction of the fifa world cup 2018 – a random forest approach with an emphasis on estimated team ability parameters. *ArXiv preprint*.
- Hvattum, L. M. and Arntzen, H. (2010). Using elo ratings for match result prediction in association football. *International Journal of Forecasting*, 26(3):460–470.
- IBM (2025). ¿qué es boosting? <https://www.ibm.com/es-es/topics/boosting>.
- Karlis, D. and Ntzoufras, I. (2003). Analysis of sports data by using bivariate poisson models. *The Statistician*, 52(3):381–393.
- Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, 36(3):109–118.
- Memmert, D., editor (2024). *Computer Science in Sport: Modeling, Simulation, Data Analysis and Visualization of Sports-Related Data*. Springer, Berlin, Heidelberg, 1st edition. Online resource, 247 pages.
- Schauburger, G. and Groll, A. (2018). Predicting matches in international football tournaments with random forests. *Statistical Modelling*, 18(5-6):460–482.
- Transfermarkt (2025). La liga - datos y estadísticas de equipos y jugadores. <https://www.transfermarkt.es/primer-division/startseite/wettbewerb/ES1>.
- Wikipedia (2024). Statistical association football predictions. https://en.wikipedia.org/wiki/Statistical_association_football_predictions.
- xgabora (2025). Club football match data 2000–2025. <https://github.com/xgabora/Club-Football-Match-Data-2000-2025>. Repositorio GitHub.